

Antes del Click: Análisis del Lado del Cliente para Mitigar la Probabilidad de Riesgo de Estafa en Compras Digitales

Mathias Alejandro Jave Diaz
Ingeniería de Software
Universidad Peruana de
Ciencias Aplicadas
Lima, Perú
0009-0009-3705-505X

Alex Ramon Alberto Avila Asto
Ingeniería de Software
Universidad Peruana de
Ciencias Aplicadas
Lima, Perú
0009-0008-5624-8482

Fidel Eugenio Garcia Rojas
Ingeniería de Software
Universidad Peruana de
Ciencias Aplicadas
Lima, Perú
0009-0007-4364-0058

Resumen—Los métodos eficaces contra el fraude en el comercio electrónico operan del lado de la plataforma utilizando telemetría interna, dejando al consumidor desprotegido en el momento de decisión. La evidencia indica que la autoconciencia no evita la victimización y que las verificaciones de legitimidad suelen realizarse después de efectuar el pago. Para abordar esta brecha, este artículo propone una arquitectura basada en una extensión de navegador que calcula un nivel estimado de riesgo de estafa en el equipo del consumidor, entendido como una escala ordinal y no como una probabilidad calibrada. El sistema resuelve ocho características (como la veracidad del dominio y la autenticidad de reseñas) a partir del documento HTML ya renderizado, sin enviar peticiones adicionales a la plataforma del vendedor, y tres de ellas se derivan en el motor de riesgo. Se incorpora una regla de decisión que distingue el riesgo detectado de la evidencia insuficiente, asegurando que la falta de información en una ficha de producto nunca se presente como seguridad. La evaluación diagnóstica sobre el conjunto de datos disponible reporta que cinco algoritmos de familias distintas clasifican la partición de prueba sin error: el conjunto es separable por construcción, de modo que el ejercicio vale como verificación del canal de procesamiento y no como medida de eficacia. El estudio define además el diseño experimental con el que la herramienta se someterá a prueba. Lo aportado es, por tanto, una propuesta arquitectónica con validación diagnóstica preliminar y protocolo experimental, y no evidencia de que el sistema mitigue la probabilidad de riesgo a la que se expone un comprador real.

Index Terms—comercio electrónico, compras digitales, extensión de navegador, nivel estimado de riesgo, riesgo del lado del cliente

I. INTRODUCCIÓN

El comercio electrónico peruano opera en un entorno donde la adopción del pago digital no está acompañada por un nivel equivalente de confianza del consumidor. Un análisis comparado de sistemas de pago en economías emergentes reporta que la falta de confianza en las instituciones constituye una barrera clave y que solo el 57 % de los adultos utiliza pagos digitales, frente al 64 % a nivel global [1]. Esa desconfianza afecta también al mercado legítimo, porque la intención y la continuidad de compra dependen del riesgo percibido [2], [3]: la incapacidad de verificar a un vendedor desconocido antes

del pago impone una fricción comercial sobre los vendedores honestos.

La prevención de estafas depende hoy de la capacidad del comprador para evaluar esa fiabilidad, y se sustenta en heurísticas de uso extendido: revisar la reputación del vendedor, desconfiar de precios inverosímiles y comprobar la dirección del sitio. El supuesto subyacente es que un comprador informado dispone de los instrumentos necesarios para protegerse.

La evidencia empírica no respalda ese supuesto. Un estudio con una muestra de 820 adultos, replicado sobre una segunda cohorte de 629, demostró que la autoconciencia sobre privacidad digital no predijo significativamente la victimización. La sobreconfianza la incrementó significativamente (razón de momios de 1.437; IC 95 % [1.234, 1.673]), concluyendo que el conocimiento por sí solo no constituye una barrera efectiva contra el fraude [4]. En la misma línea, la verificación del comprador tiende a ocurrir *posterior* a que el pago ya se ha realizado [5].

La eficacia de estas heurísticas se ve comprometida por la pérdida de poder discriminante de los indicadores tradicionales. Los certificados SSL, antes considerados un indicador de fiabilidad, son obtenidos actualmente mediante servicios automatizados [6]. La reputación visible del vendedor ha sido demostrada como manipulable por construcción del mercado [7]. Las dos heurísticas más difundidas la conexión cifrada y la buena puntuación son precisamente las que un defraudador competente puede exhibir legítimamente.

Sin embargo, existen métodos eficaces contra el fraude que operan en un plano inaccesible para el comprador. Los sistemas desplegados por los operadores de plataformas alcanzan desempeños elevados mediante el uso de telemetría interna [8]. Las contramedidas de seguridad revisadas en la literatura se implementan y financian dentro de las organizaciones de comercio [9]. Ninguna de estas soluciones alcanza al comprador que evalúa una ficha en una plataforma o interactúa con un vendedor que no las ha adoptado.

El presente trabajo propone desplazar la evaluación de riesgo desde el juicio subjetivo del comprador hacia un sistema

de estimación automática que se ejecute en su navegador, sobre la información que ya tiene disponible y antes de que se efectúe el pago. La pregunta central que se aborda, y que este trabajo deja planteada para su evaluación empírica posterior, es si un conjunto de características extraíbles del lado del cliente sin acceso privilegiado a la plataforma y sin recolección automatizada de datos resulta suficiente para generar una advertencia útil en el punto de decisión. Esa suficiencia es aquí una hipótesis de diseño, no un resultado.

Una advertencia se considera útil si cumple tres condiciones: (1) se genera antes de que el pago se efectúe, (2) se basa en al menos cuatro características verificables, y (3) distingue explícitamente entre riesgo detectado e información insuficiente. Esta última condición es crítica: un sistema que presentara como seguro aquello que solo desconoce trasladaría al comprador un riesgo que no ha evaluado.

Conviene fijar aquí la terminología que el artículo emplea. El sistema calcula un *nivel estimado de riesgo*: una escala ordinal alto, moderado o bajo que no constituye una probabilidad calibrada, pues nada en el diseño garantiza que sus niveles correspondan a frecuencias observadas de fraude. Ese nivel, junto con la declaración de evidencia insuficiente cuando corresponde, conforma el *veredicto* que la extensión muestra al comprador. El sistema no emite un dictamen categórico de fraude. Esta distinción tiene dos implicaciones operativas. Por un lado, admite declaraciones explícitas de insuficiencia de evidencia en lugar de forzar decisiones binarias. Por otro, el sistema se evalúa en función del cambio que induce en la decisión de compra y del costo de las advertencias infundadas, en lugar de utilizar métricas de clasificación estándar contra una verdad de referencia inexistente en la ficha de producto.

Las contribuciones de este trabajo son tres. En primer lugar, un conjunto de ocho características de riesgo extraíbles desde el cliente. Estas características vienen acompañadas de una regla explícita que distingue el riesgo detectado de la evidencia insuficiente, garantizando que la ausencia de información nunca se presente como seguridad. Se presenta como un mecanismo de diseño: está emparentado con los esquemas de abstención u opción de rechazo conocidos en clasificación, y lo que aquí se propone es su aplicación a la evaluación de riesgo del lado del comprador, donde los sistemas de detección de fraude existentes operan sobre datos completos y no abordan el problema de la información parcial. Establecer en qué medida ello constituye una novedad frente a esos esquemas exige la comparación sistemática que este trabajo aún no realiza. En segundo lugar, una arquitectura de tres capas cuyo componente principal es una extensión de navegador. Se presentan los diseños de los módulos clave y se entrenaron prototipos de los clasificadores de vendedor y reseñas. En tercer lugar, un protocolo de validación en dos fases que separa la observabilidad de las características de la eficacia del veredicto, identificando las amenazas a la validez que condicionan las conclusiones.

Cabe precisar qué es exactamente lo que se presenta. Este artículo aporta tres cosas de naturaleza distinta: una propuesta arquitectónica, una validación diagnóstica preliminar sobre el

único conjunto de datos disponible y un protocolo experimental para la etapa siguiente. La extensión de navegador y el analizador de dominio no han sido implementados; los clasificadores son prototipos preliminares entrenados sobre datos sintéticos cuyas limitaciones se analizan en la Sección IV. Nada de lo que sigue debe leerse como evidencia de que la propuesta mitigue la probabilidad de riesgo a la que se expone un comprador real.

El resto del artículo se organiza de la siguiente manera. La Sección II revisa el trabajo relacionado; la Sección III presenta el contexto conceptual, la arquitectura propuesta y el protocolo de validación; la Sección IV reporta la verificación preliminar y discute sus límites; la Sección V presenta las conclusiones y el trabajo futuro.

II. TRABAJO RELACIONADO

La estimación de riesgo en comercio electrónico constituye un campo de investigación consolidado. Esta sección lo analiza en cinco dimensiones: inteligencia artificial para estimación de riesgo, detección de vendedores fraudulentos desde la plataforma, identificación de reseñas manipuladas, detección de sitios de suplantación y contramedidas implementadas por las organizaciones comerciales. Un apartado final identifica la brecha que este trabajo aborda. Los avances se concentran en el lado del operador de la plataforma, y rara vez llegan al comprador en el momento de la decisión de compra. La Tabla I resume esa lectura y sitúa la presente propuesta frente a cada línea.

II-A. Inteligencia artificial aplicada a la estimación de riesgo

El aprendizaje profundo se ha consolidado como la tecnología preferida para tareas como estimación de riesgo y toma de decisiones en plataformas de comercio electrónico [19]. Los sistemas basados en reglas no escalan ante el volumen y el carácter adaptativo de las amenazas actuales. El contenido generado por usuarios como reseñas, calificaciones e imágenes resulta decisivo en la decisión de compra y, simultáneamente, altamente vulnerable a la manipulación y al fraude coordinado.

Un ejemplo cuantificado ilustra tanto el nivel alcanzado como las condiciones que lo hacen posible: un modelo híbrido de red convolucional con máquina de soporte vectorial optimizada alcanza una exactitud del 96.23 % al clasificar el riesgo crediticio de empresas de comercio transfronterizo, a partir de información financiera de la contraparte y evaluaciones de la plataforma que no son accesibles desde el navegador de quien está por comprar [18].

Los algoritmos que sustentan esta línea de investigación son identificables. En la detección de reseñas manipuladas predominan los modelos de lenguaje basados en transformadores: variantes de BERT ajustadas al dominio del comercio electrónico [14], arquitecturas adversariales sobre la misma familia [15] y redes neuronales profundas aplicadas a reseñas de plataformas concretas [16]. En ocasiones se combinan con memorias de largo y corto plazo bidireccionales y con herramientas de explicabilidad para justificar el veredicto [14].

TABLA I
LÍNEAS DE TRABAJO REVISADAS, SITUADAS FRENTE A LA PROPUESTA

Línea	Datos que requiere	Dónde se ejecuta	Cuándo actúa	Salida	Límite para el comprador
Fraude del vendedor [8], [10]–[12]	Registros transaccionales, huellas de dispositivo, grafos de interacción	Operador de la plataforma	Durante o después de la transacción	Marca sobre cuenta o transacción	No accede a los datos ni al resultado
Autenticidad de reseñas [13]–[16]	Texto de reseñas y metadatos del corpus	Plataforma o investigador	Tras la publicación de la reseña	Etiqueta por reseña	No produce un juicio sobre el vendedor ante la compra
Suplantación de sitios [6], [17]	Localizador, registro del dominio y resolución	Proveedor de seguridad o institución financiera	Antes de la visita, sobre listas de URL	Etiqueta de <i>phishing</i>	Cubre la identidad del sitio, no al vendedor ni sus reseñas
Riesgo crediticio transfronterizo [18]	Información financiera de la contraparte y evaluaciones internas	Plataforma	Previo a la operación comercial	Puntaje de riesgo crediticio	Objeto distinto y datos inaccesibles desde el navegador
Contramedidas del comercio [9]	Infraestructura del propio comercio	Organización comercial	Permanente	Controles de seguridad	Solo protege frente al comercio que las adopta
Este trabajo	Ficha ya renderizada, más registro y resolución del dominio	Navegador del comprador y servicio propio	Antes del pago	Nivel estimado de riesgo o evidencia insuficiente	Cobertura limitada a lo visible; sin evaluación empírica

En la estimación de riesgo del vendedor y en la detección de sitios de suplantación predominan, en cambio, los métodos de ensamble y los clasificadores de margen: bosques aleatorios, máquinas de soporte vectorial, árboles de decisión y gradiente potenciado aparecen de forma recurrente [10]–[12]. El marco de detección más reciente combina cuatro de ellos con selección de características mediante SHAP y eliminación recursiva [6]. Esta distribución no es casual: el texto libre de las reseñas exige representaciones contextuales, mientras que los atributos estructurales de una ficha heterogéneos y de baja dimensionalidad se ajustan mejor a los métodos basados en árboles.

Estos enfoques se sitúan invariablemente en la plataforma o en el operador del servicio, que son quienes disponen de los registros y ejecutan los modelos, y aun ahí admiten limitaciones: los detectores más avanzados pueden ser eludidos mediante perturbaciones adversariales u ofuscación lingüística [19]. La defensa centralizada, por sólida que sea, deja pasar casos que alcanzan al comprador sin que este disponga de instrumento alguno.

II-B. Detección de fraude desde la plataforma

La detección de fraude en comercio electrónico ha alcanzado madurez metodológica [10]. Un exponente reciente combina razonamiento basado en casos con un sistema multiagente para alcanzar un AUC de 0.979 sobre 1.27 millones de instancias, resistiendo la deriva del comportamiento fraudulento [8]. Dicho desempeño se sostiene sobre datos que solo el operador posee: registros transaccionales, huellas de dispositivo y un grafo de interacción de el comprador que evalúa una ficha no tiene acceso.

II-C. Reseñas manipuladas

La segunda línea de investigación aborda la autenticidad de las reseñas. Además de los detectores basados en contenido textual, esta línea incorpora enfoques de fusión que combinan diversas características de la reseña [13]. Un modelo de

competencia demuestra que en equilibrio el vendedor auténtico no adquiere reseñas falsas mientras que el falsificador puede hacerlo para inducir a error al comprador [7]. La manipulación de la reputación no es, por tanto, una anomalía sino un comportamiento previsible. La cantidad de reseñas falsas en equilibrio decrece con la fracción de consumidores capaces de interpretar correctamente los indicadores de la ficha. Esto sitúa la información del comprador y no solo la capacidad de detección de la plataforma como palanca de mitigación efectiva.

II-D. Suplantación de sitios y análisis de dominio

La tercera línea proviene de la seguridad informática. En [17] se detectan localizadores uniformes de recursos (URL) de *phishing* en dominios aparcados a partir de características derivadas del registro, aplicándolo a una institución financiera; en [6] se propone un marco de detección sobre 1 353 URL con selección de características por explicaciones aditivas de Shapley (SHAP) y eliminación recursiva, alcanzando una exactitud del 98.4 %.

Lo más relevante de este último para el presente trabajo no es el desempeño del clasificador sino el diagnóstico que lo motiva: el certificado SSL válido dejó de discriminar sitios legítimos de fraudulentos. Los atacantes obtienen certificados mediante servicios automatizados, y las listas de bloqueo del navegador no alcanzan a cubrir dominios desplegados y retirados en horas [6].

II-E. Contramedidas del lado del comercio

Una revisión sistemática de métodos de seguridad en comercio electrónico [9] inventaría siete familias de controles y concluye que ninguna basta por sí sola, por lo que la defensa debe articularse en capas. Las siete, no obstante, se implementan y financian dentro de la organización comercial. Ninguna protege al comprador que interactúa con una plataforma o un vendedor que no las ha adoptado.

II-F. Brecha de investigación

El comprador ocupa una posición singular: existen métodos eficaces contra vendedores fraudulentos, reseñas manipuladas y suplantación de sitios, pero todos requieren datos, infraestructura o autoridad de los que él carece. Las recomendaciones dirigidas a él son de naturaleza educativa y de eficacia limitada [4], [5]. En los trabajos revisados no se identificó ninguno que combine características de dominio, de vendedor y de reseñas en un instrumento que se ejecute del lado del comprador y emita su advertencia antes del pago. Esta revisión es selectiva y no sigue un protocolo sistemático, de modo que la afirmación se limita a lo revisado: establecer la ausencia de tales trabajos en la literatura exigiría una búsqueda sistemática, que queda como trabajo pendiente. Esa es la brecha que este trabajo aborda. Las características propuestas se apoyan en elementos presentes en cualquier ficha de producto con información pública, por lo que su traslado a plataformas como MercadoLibre, Amazon, eBay o AliExpress constituye una *hipótesis de transferibilidad*: su observabilidad real en cada una debe medirse antes de darla por válida, y esa medición es el objeto de la Fase 1 del protocolo de la Sección III-B.

III. METODOLOGÍA

Esta sección llama *extensión* a la aplicación de navegador que recolecta del DOM los datos con los que se resuelven las características, *motor de riesgo* al conjunto de servicios que derivan las características restantes y calculan el nivel estimado de riesgo, y *sistema* a la arquitectura completa, incluida la persistencia.

La unidad de análisis es una *ficha de producto* que el comprador tiene abierta en su navegador: el sistema no recorre catálogos ni consulta interfaces privilegiadas de la plataforma, sino que opera sobre la misma información que el comprador ya tiene delante. Esta restricción gobierna todas las decisiones de diseño que siguen. Separa esta propuesta de los sistemas de detección desplegados por el operador del comercio [8].

III-A. Contexto

1. *Características extraíbles del lado del cliente*: Para los efectos de esta arquitectura, se define como *característica extraíble del lado del cliente* a todo atributo de una publicación que cumpla tres condiciones simultáneas: ser visible para el comprador antes del pago, residir en el documento ya entregado al navegador y no requerir acceso a interfaces internas de la plataforma. La puntuación del producto, el número de reseñas y el nombre de dominio cumplen estrictamente con estos criterios.

Esta distinción separa el presente trabajo de la línea dominante en detección de fraude, que depende de la telemetría interna ya mencionada. El comprador dispone de un conjunto de características restringido, por lo que la pregunta central que este trabajo aborda es si esos datos accesibles resultan suficientes para producir una advertencia útil.

La definición se refiere al origen del dato, no al lugar donde se computa, y conviene separar tres niveles que el resto del artículo mantiene distintos. El *dato observado* lo lee la extensión

en el documento ya renderizado: la puntuación, la presencia de reseñas, el volumen de ventas, la garantía anunciada, el medio de pago declarado y el nombre de dominio. La *característica derivada* la calcula el motor de riesgo a partir de ese dato o de otro accesible públicamente, como ocurre con la veracidad de dominio, que parte del nombre de host y consulta servicios de registro y resolución. La *salida de modelo* es el valor que produce un componente de aprendizaje automático, como la reputación del vendedor o la proporción estimada de reseñas no auténticas. Las tres se apoyan en lo que el comprador tiene delante, y ninguna exige telemetría interna de la plataforma; lo que cambia es dónde se computan, según precisa la Tabla II.

2. *Lectura del DOM y recolección automatizada*: La operación que realiza la extensión requiere una caracterización precisa. Una revisión sistemática define el *web scraping* y el *web crawling* como el proceso automatizado de extracción de datos en el que las herramientas navegan a través de múltiples páginas [20]. La extensión propuesta no realiza ninguna de las dos operaciones: no navega, porque es el usuario quien decide qué ficha abrir; no recorre múltiples páginas, porque opera sobre el documento que el navegador ya renderizó. Su operación consiste en interpretar contenido que ya le había sido entregado.

La misma revisión advierte que las herramientas apoyadas en selectores predefinidos son susceptibles a cambios de maquetación, y que entre los desafíos del área figuran los riesgos legales [20]: lo primero se declara como amenaza a la validez más adelante, y lo segundo es la razón para no retransmitir contenido de la plataforma más allá de las características que el veredicto requiere.

3. *Protección de pago declarada*: Las plataformas de comercio de mayor tamaño publican esquemas mediante los cuales retienen el pago hasta la conformidad del comprador o garantizan su devolución ante incumplimiento. Esa declaración es un compromiso público y verificable en la propia ficha, y constituye por ello una característica legítima. Su ausencia, en cambio, no es igualmente informativa: un vendedor independiente puede ofrecer condiciones equivalentes sin anunciarlas, o anunciarlas donde la extensión no alcanza a leer. Tratar el silencio como evidencia de inseguridad convertiría una limitación del observador en una acusación sobre el observado, tanto más cuanto que las contramedidas disponibles se despliegan y financian del lado del comercio [9] y su ausencia visible correlaciona con el tamaño del vendedor antes que con su honestidad.

La arquitectura se organiza en tres capas: cliente, motor de riesgo y persistencia. La separación desacopla la observación del DOM, que ocurre en el navegador, del análisis de riesgo, que requiere servicios externos, y de la persistencia, que sostiene la trazabilidad; permite además sustituir los algoritmos de clasificación sin modificar la capa de observación.

III-B. Método

1. *Capa cliente: observación sin recolección automatizada*: La capa cliente se implementa como una *aplicación nativa en el navegador* (una extensión) que se activa cuando

el usuario abre una ficha de producto en una plataforma soportada. La extensión recorre el árbol DOM ya renderizado, localiza mediante selectores los elementos que exponen los atributos de interés precio, puntuación, número de reseñas, identidad del vendedor, medios de pago anunciados, políticas de garantía y construye un vector de observaciones que envía al motor de riesgo. Conviene ser preciso sobre el reparto: la extensión no resuelve por sí sola las ocho características, sino que recolecta los datos necesarios para resolverlas. Tres de ellas veracidad de dominio, reputación del vendedor y autenticidad de reseñas las deriva el motor de riesgo, según detalla la Tabla II, y la agregación del veredicto ocurre también allí. La extensión constituye el componente principal de esta propuesta, y no por conveniencia de implementación. Es el único punto del sistema que coincide, en espacio y en tiempo, con el instante en que el comprador decide. Se ejecuta sobre la ficha que él tiene abierta, sin mediación de la plataforma y antes de que el pago ocurra. Ningún otro componente de esta arquitectura coincide de ese modo con el instante de la decisión.

Conviene precisar qué sale del navegador y qué no: salen los valores de los atributos leídos, el nombre de host y el identificador de la publicación, por petición cifrada; no salen el documento completo, el contenido de otras pestañas ni dato alguno de la sesión que el comprador mantenga con la plataforma. La extensión no almacena datos sensibles del usuario.

Esta capa existe porque la advertencia que ha de llegar antes del pago debe producirla el sistema y no el juicio del comprador [4], [5]. La ventaja técnica es que la información necesaria ya fue entregada al navegador. El sistema no emite hacia la plataforma del vendedor ninguna petición que el comprador no hubiera cursado en cualquier caso.

«Del lado del cliente» no significa, sin embargo, «sin servidor»: el vector observado viaja al motor de riesgo, el analizador de dominio consulta servicios de registro, y cada consulta queda registrada. La propuesta elimina la dependencia respecto de la plataforma del vendedor a costa de introducir un nuevo tercero de confianza, con la política de retención y anonimización que ello exige. Su otra contrapartida es la fragilidad ante cambios de maquetación [20].

2. *Conjunto de características y regla de abstención ante evidencia ausente*: El motor de riesgo trabaja sobre ocho características, resumidas en la Tabla II. Cada característica se define junto con la capa que la computa, su dominio de valores y de manera central para esta propuesta el valor que toma cuando no puede determinarse.

La *protección de pago declarada* fija el criterio que rige al resto. Plataformas como MercadoLibre, Amazon o AliExpress declaran en la ficha que retienen el pago o que garantizan la devolución ante incumplimiento, y la extensión detecta esa declaración; cuando no la encuentra, el sistema no infiere que el pago sea inseguro sino que registra la característica como *no verificable*, según la distinción establecida en la subsección anterior.

Esta regla se aplica de manera uniforme: para toda caracte-

TABLA II
CONJUNTO DE CARACTERÍSTICAS, ORIGEN Y COMPORTAMIENTO ANTE EVIDENCIA AUSENTE

Característica	Se computa en	Valores	Si no hay evidencia
Protección de pago declarada	Cliente	declarada / no declarada	<i>no verificable</i>
Veracidad de dominio	Backend	escala ordinal	<i>no verificable</i>
Reputación del vendedor	Backend	escala ordinal	<i>no verificable</i>
Autenticidad de reseñas	Backend	proporción estimada	<i>no verificable</i>
Puntuación del producto	Cliente	continua	ausente
Presencia de reseñas	Cliente	binaria	ausente
Políticas de garantía	Cliente	ordinal	<i>no verificable</i>
Volumen de ventas	Cliente	entero	ausente

rística se distingue entre valor conocido, valor *ausente* y valor *no verificable*. Los dos últimos estados no son intercambiables. Una característica es *ausente* cuando el atributo no existe en la ficha y esa inexistencia es en sí misma una observación: una publicación sin reseñas no tiene puntuación del producto, y la lectura correcta no es que se ignore su valoración sino que no ha sido valorada. Es *no verificable* cuando el atributo puede existir pero el sistema no logró comprobarlo: un vendedor independiente puede ofrecer garantía y no anunciarla en la ficha, o el analizador de dominio puede no obtener respuesta del servicio de registro. El primer estado informa sobre la publicación; el segundo, solo sobre los límites del observador. Una característica se considera *resuelta* cuando toma un valor conocido; los otros dos estados la dejan sin resolver, y la Tabla II indica cuál adopta cada una cuando la ficha no aporta evidencia. El agregador propaga esa distinción hasta el veredicto mediante dos condiciones que deben cumplirse conjuntamente.

La primera es de cobertura. Sea r el número de características resueltas de las ocho; el sistema exige $r \geq 4$. El umbral mínimo se estableció para garantizar al menos una característica por dimensión de riesgo (tres dimensiones) más una redundancia. Un umbral de tres podría satisfacer la condición dimensional sin margen de error; uno de cinco reduciría excesivamente los casos en que el sistema puede emitir un veredicto. La segunda es de suficiencia por dimensión. Las ocho características cubren tres dimensiones de riesgo distintas: la identidad del sitio (veracidad de dominio), la fiabilidad del vendedor (reputación, volumen de ventas, políticas de garantía y protección de pago declarada) y la evidencia de la comunidad (puntuación, presencia y autenticidad de reseñas). El sistema exige que al menos una característica de cada dimensión se haya resuelto.

La elección de ocho características responde a la necesidad de cubrir las tres dimensiones con más de un indicador en las

dos primeras, lo que permite detectar inconsistencias y reducir la influencia de valores atípicos. Es una decisión de diseño inicial y no un resultado: que ocho basten, y que añadir más no aporte lo suficiente para justificar su costo de extracción, son afirmaciones que requieren un análisis de ablación sobre datos reales, previsto para la etapa siguiente.

Dos aspectos de esta regla quedan igualmente sujetos a verificación empírica. Los umbrales $r \geq 4$ y $r \geq 6$ se eligieron por las razones expuestas, que no acreditan que sean los valores adecuados: la Fase 1 del protocolo de validación, al medir qué se resuelve en fichas reales, es la que permitirá ajustarlos. Y todas las características resueltas cuentan igual dentro de su dimensión, supuesto discutible cuando una señal débil basta para dar por cubierta una dimensión entera; ponderarlas por su confiabilidad es una alternativa que este trabajo deja abierta.

Cuando ambas condiciones se satisfacen, el veredicto se emite con un nivel de confianza derivado de la cobertura: alta si $r \geq 6$, media en caso contrario. Cuando alguna falla, el sistema no emite riesgo sino *evidencia insuficiente*, junto con la lista de características que no pudo resolver.

La segunda condición distingue esta regla de un simple conteo: un umbral global trataría por igual la pérdida de tres características redundantes y la de la única que informa sobre la identidad del sitio, dejando al comprador sin protección frente a la suplantación. La justificación de fondo es la asimetría de costos: presentar como seguro aquello que solo es desconocido traslada al comprador un riesgo que el sistema no ha evaluado.

3. *Descomposición en servicios*: El motor de riesgo de la Fig. 1 no es un bloque único; se despliega en cuatro servicios desacoplados. Un analizador de veracidad de dominio verifica la legitimidad del sitio web consultando registros DNS y patrones morfológicos; un analizador de reputación evalúa el historial y las políticas del vendedor; una API de estimación de riesgo calcula el nivel estimado de riesgo mediante un bosque aleatorio; y una API de detección de reseñas falsas identifica contenido potencialmente fraudulento mediante un modelo DistilBERT. La API centralizadora recibe las observaciones de la extensión, delega las características relevantes a los cuatro servicios y agrega los resultados para emitir el veredicto. La persistencia se resuelve sobre una base relacional que almacena las consultas y sus resultados para trazabilidad y reentrenamiento. La separación responde a una propiedad que el sistema necesita: cada servicio puede actualizarse de forma independiente cuando cambian las características disponibles o los patrones lingüísticos del fraude, sin interrumpir el servicio ni versionar la interfaz que consume la extensión.

4. *Analizador de veracidad de dominio*: El analizador de dominio recibe el nombre de host de la ficha y devuelve una estimación ordinal de veracidad. Se entiende aquí por *veracidad de dominio* el grado en que el dominio que aloja la ficha se corresponde con una operación establecida, y no con un despliegue reciente o efímero de los asociados a la suplantación. Se expresa en una escala ordinal cuyo nivel central se reserva a la ausencia de evidencia, de modo que un dominio sobre el que no se obtuvo información no queda




Fig. 1. Arquitectura lógica propuesta. La capa cliente recolecta del DOM renderizado los datos de las características y los envía a la API centralizadora del motor de riesgo, que se descompone en cuatro servicios: analizador de veracidad de dominio, analizador de reputación, API de estimación de riesgo y API de detección de reseñas falsas. La API centralizadora agrega los resultados y almacena las consultas en la capa de persistencia.

situado ni entre los confiables ni entre los sospechosos. Su entrada se compone de atributos del registro del dominio, de la cadena de resolución incluidos los registros de nombre canónico (CNAME) y de la coincidencia con patrones morfológicos asociados a campañas de suplantación.

Este módulo es necesario porque ni el certificado SSL ni las listas de bloqueo del navegador discriminan ya la suplantación [6]. La ventaja de analizar registro y resolución en lugar de contenido es que estos atributos aportan señales complementarias, menos dependientes del contenido visible que el defraudador controla. Se ha mostrado que características derivadas del registro permiten detectar URL de *phishing* en dominios aparcados [17], lo que sostiene la viabilidad del enfoque sobre esta clase de atributos. El módulo no reemplaza la comprobación de certificado, que la literatura de seguridad en comercio electrónico caracteriza como el control fundacional y de menor costo [9], sino que la complementa en la dimensión donde aquella dejó de ser informativa.

5. *Modelos de inferencia sobre vendedor y reseñas*: Dos componentes de aprendizaje automático completan el motor. El primero estima el riesgo del vendedor a partir del vector de características extraídas y devuelve un nivel ordinal; el segundo estima la proporción de reseñas presumiblemente

fraudulentas en la ficha. La novedad de la propuesta no reside en ellos, sino en cómo se integran sus salidas con las demás características bajo la regla de abstención ya descrita, de modo que su configuración se documenta solo en la medida en que hace reproducible el prototipo.

Para la estimación de riesgo del vendedor se emplea un bosque aleatorio y no una arquitectura de mayor capacidad, por tres propiedades que el problema exige. La dimensionalidad: el vector de entrada contiene ocho características heterogéneas binarias, categóricas, discretas y continuas, un régimen en el que los métodos de ensamble por árboles operan sin normalización ni codificaciones adicionales. La interpretabilidad: el modelo expone la contribución relativa de cada característica. Y el costo: la inferencia sobre cien árboles es despreciable frente a la latencia de red de la consulta. La elección responde por tanto a requisitos técnicos, y no a una superioridad empírica sobre otras familias de algoritmos, extremo que los datos disponibles no permiten arbitrar, como muestra la Sección IV.

La interpretabilidad requiere una precisión, porque de ella depende la explicación que acompaña al veredicto. La contribución relativa de las características que el bosque aleatorio expone es una medida global, referida al modelo entero, y no explica por qué una publicación concreta recibió el nivel que recibió. La explicación por caso exige un procedimiento distinto importancia por permutación local, valores de Shapley o el recorrido de decisión del árbol cuya elección este trabajo deja abierta y cuyo costo de cómputo debe medirse contra el tiempo que el comprador espera.

El clasificador del que se dispone actualmente es un prototipo preliminar y no representa al modelo del sistema propuesto: cien árboles entrenados sobre siete entradas, con 10 000 registros sintéticos de tres clases equilibradas, partición 80/20 y semilla fija, sin la veracidad de dominio que este trabajo incorpora. Añadirle exige reentrenar el modelo sobre un conjunto que la contenga, y su ausencia es consecuencia de que este trabajo describe la arquitectura propuesta y no una implementación ya construida.

El segundo componente estima la autenticidad de las reseñas con DistilBERT, un codificador transformador destilado cuya configuración de ajuste recoge la tabla de configuración. La elección de una variante destilada responde a una restricción operativa: la inferencia ocurre entre la consulta de la extensión y la emisión del veredicto, de modo que su costo incide sobre el tiempo que el comprador espera. Seis capas y 66.96 millones de parámetros reducen ese costo frente a un codificador completo; la ejecución en precisión de 32 bits sobre unidad central de proceso evita exigir aceleración por hardware. La contrapartida es una capacidad de representación menor, cuya repercusión sobre la exactitud debe cuantificarse en la validación.

Su entrada no es únicamente el texto de la reseña: se serializan conjuntamente la categoría del producto, la calificación asignada y el texto, porque una misma formulación puede resultar verosímil o anómala según la calificación que la acompaña. El ajuste se realizó durante una época, con tasa

de aprendizaje de 2×10^{-5} , lotes de dieciséis secuencias de hasta 512 *tokens* y dos clases. Este trabajo no evalúa el clasificador de reseñas: esa configuración se declara para hacer reproducible el componente, no para respaldar afirmación alguna sobre su desempeño. Ni el corpus de ajuste ni sus métricas de prueba forman parte de lo reportado aquí, y la brevedad del ajuste es una limitación que su evaluación futura deberá considerar.

La inferencia sobre reseñas es necesaria porque, según el resultado de equilibrio citado en la Sección II, la reputación visible es manipulable por construcción [7]: tomar la puntuación agregada como indicador de confianza coincide con el comportamiento que el vendedor fraudulento busca inducir. La arquitectura incorpora por ello la estimación de autenticidad de las reseñas como característica independiente de la puntuación, si bien la forma en que ambas deben combinarse y en particular si la segunda debe corregir a la primera antes de la clasificación constituye una decisión de diseño abierta que la validación deberá resolver.

6. *Agregación, presentación y persistencia:* El agregador combina las características resueltas en un veredicto con cuatro desenlaces posibles: riesgo alto, moderado o bajo cuando la evidencia disponible permite decidir, y *evidencia insuficiente* cuando no. Los tres primeros se acompañan del nivel de confianza y de la lista de características que los sustentan; el cuarto, de las características que no pudieron resolverse. La presentación es deliberadamente explicativa: junto al veredicto se muestra qué características se verificaron, cuáles quedaron indeterminadas y qué acredita cada una, conforme al requisito de trazabilidad que la literatura de detección de fraude ha ido incorporando frente a los clasificadores opacos [8].

La interfaz extiende el botón estándar del navegador: al abrirla, el comprador ve un indicador de color con el veredicto, la lista de características verificadas con su valor y la de las no resueltas con la razón de la falla.

Finalmente, cada consulta se registra en una base de datos junto con las características extraídas y el veredicto emitido. El registro habilita la trazabilidad de cada advertencia y constituye el conjunto de datos con el que los modelos se reentrenarán. Dado que la información asociada a una consulta puede revelar hábitos de compra, el esquema se acota a lo que esas dos funciones exigen: plataforma, identificador de la publicación, nombre de host, valor y estado de cada característica, veredicto emitido y marca temporal. No se almacenan el documento de la ficha, el texto de las reseñas ni la identidad del comprador cuando este usa la extensión sin cuenta. El protocolo de validación fija los términos de retención y disociación que rigen durante la validación.

Esta sección describe el protocolo con el que se someterá a prueba la arquitectura completa. Como meta piloto inicial se fija que la extensión resuelva al menos el 70 % de las características en fichas de plataformas grandes y al menos el 40 % en vendedores independientes. Son valores de referencia para orientar la primera medición, no umbrales de éxito acreditados por evidencia previa, y se revisarán con los datos que arroje la Fase 1. No se fijan aquí metas sobre la proporción

de advertencias infundadas ni sobre el efecto en la decisión de compra: ambas exigen una referencia externa sobre la legitimidad de cada ficha de la que este protocolo todavía no dispone.

7. *Validación:* La validación se ejecutará en el Perú, sobre las plataformas y los hábitos descritos en la Sección I. Esa elección delimita el alcance de las conclusiones empíricas, no el de la arquitectura: las características de la Tabla II se derivan de elementos presentes en cualquier ficha de producto y no de particularidades del mercado peruano. De ahí se sigue una hipótesis de transferibilidad, no una propiedad demostrada: que la propuesta opere en otros mercados depende de que esas características resulten observables en ellos, lo que exige medir su cobertura en cada caso.

La validación se organiza en dos fases con objetivos separables.

Fase 1: observabilidad de las características. Antes de evaluar la utilidad del veredicto es necesario establecer qué fracción de las características de la Tabla II resulta efectivamente legible en fichas reales. Sobre una muestra de fichas de producto de las plataformas de mayor uso en el Perú se registrará, para cada característica, si pudo resolverse o si quedó indeterminada, distinguiendo entre plataformas grandes y vendedores independientes. El desenlace relevante no es un porcentaje agregado sino su distribución: una arquitectura que solo resolviera características en las plataformas que ya ofrecen garantías carecería de utilidad precisamente en el segmento donde el riesgo se concentra.

Fase 2: comportamiento de compra con la herramienta. Un diseño con dos grupos, con y sin la extensión activa, enfrentará a los participantes al mismo conjunto de fichas reales. La asignación al grupo será aleatoria y el orden de presentación de las fichas se contrabalanceará entre participantes, para que el aprendizaje sobre la tarea no se confunda con el efecto de la herramienta. La población objetivo son compradores digitales peruanos de entre 18 y 60 años. La muestra prevista de cincuenta participantes es una muestra piloto, dimensionada por factibilidad: permite estimar la variabilidad de las medidas y detectar problemas del protocolo, no alcanzar potencia estadística, que deberá calcularse a partir de esa variabilidad antes del estudio definitivo. Todos otorgarán su consentimiento de forma voluntaria antes de comenzar, y las sesiones se conducirán de manera presencial o en línea, según su disponibilidad. Los registros de consulta antes descritos se recogerán disociados del participante que los originó, se conservarán únicamente durante el periodo de análisis y se eliminarán al cierre del estudio; ningún dato que permita reconstruir el historial de compra de una persona identificada forma parte de lo que el protocolo almacena.

Las medidas de esta fase se eligieron bajo una restricción que conviene declarar: el diseño no dispone de una verdad de referencia sobre cada ficha. Establecer si un vendedor es fraudulento exige evidencia sobre operaciones consumadas, denuncias verificadas, retiros de la plataforma que la ficha no contiene y que este protocolo no produce. Por eso no se miden aquí la tasa de identificación correcta ni la tasa de falsos

TABLA III
DIMENSIONES DEL INSTRUMENTO DE VALIDACIÓN CON USUARIOS

Dimensión	Qué establece
Usabilidad	Si el veredicto y su explicación se interpretan sin instrucción previa (bloque SUS)
Confianza percibida	Si el participante considera fundada la advertencia que recibe
Riesgo percibido	Si su estimación del riesgo de la ficha varía al disponer de la herramienta
Intención de uso y recomendación	Si declararía seguir usándola fuera del entorno de prueba
Influencia en la decisión	Si la advertencia modificó lo que habría hecho sin ella

positivos sobre comercios legítimos: ambas presuponen esa referencia, y construirla es un requisito previo del estudio de eficacia, no un subproducto de este.

Se medirá, en cambio, lo que el diseño sí puede observar. Del comportamiento: la decisión de compra sobre cada ficha en uno y otro grupo, la proporción de decisiones que el participante revierte tras leer el veredicto y el tiempo hasta decidir. Del sistema: la cobertura de características alcanzada en cada ficha y la proporción de fichas en que la regla se abstiene, magnitud que gobierna la utilidad del instrumento, pues una herramienta que se abstiene casi siempre no llega a informar decisión alguna. La percepción del participante se recoge mediante un cuestionario estructurado de quince ítems con respuesta en escala de Likert de cinco puntos, organizado en las cinco dimensiones de la Tabla III. Solo el bloque de usabilidad emplea un instrumento validado, la Escala de Usabilidad del Sistema [21]; las cuatro dimensiones restantes constituyen un instrumento propio, sujeto a validación en el propio estudio piloto, del que se reportará la consistencia interna antes de interpretar sus resultados. La dimensión de influencia en la decisión es autorreportada y no se emplea como indicador de eficacia: que una advertencia influya no implica que la decisión resultante sea mejor, y establecerlo exige la referencia externa que esta fase no tiene.

La asimetría de costos que motiva la regla de abstención se mantiene como principio de diseño y no como resultado medible en esta fase. Un instrumento que advierte con excesiva frecuencia pierde credibilidad y su costo recae sobre comercios honestos; cuantificar ese costo exige la verdad de referencia que el estudio de eficacia deberá construir. Por eso el veredicto de riesgo y el de evidencia insuficiente se mantienen separados: son resultados distintos y su evaluación no puede confundirse.

IV. RESULTADOS Y DISCUSIÓN

IV-A. Verificación preliminar del vector de características

Para verificar que el vector de ocho características de la Tabla II contiene información discriminante, se construyó un conjunto sintético de 10 000 registros con tres clases equilibradas. El conjunto se construyó ante la ausencia de un conjunto etiquetado público de fichas de vendedores peruanos: sus variables y rangos se derivaron de los factores de riesgo

identificados en la Sección II, y las etiquetas se asignaron mediante reglas deterministas sobre esas mismas variables. Declarar esta procedencia es indispensable para interpretar lo que sigue. Sus siete entradas corresponden a siete de las ocho de la Tabla II. La veracidad de dominio, que este trabajo introduce, es la única que no forma parte de ese vector. Se entrenaron cinco algoritmos de familias distintas sobre la misma partición 80/20 con semilla fija, y se validaron además mediante validación cruzada estratificada de cinco pliegues sobre el conjunto completo. Los resultados muestran que los cinco algoritmos clasifican correctamente los 2000 registros de prueba, sin desviación entre pliegues.

Los experimentos se ejecutaron sobre Ubuntu 24.04.3 LTS con Python 3.11 y scikit-learn, en un procesador Intel Xeon E3-1240 v5 y sin aceleración gráfica. Las máquinas de soporte vectorial y el clasificador de vecinos más cercanos se encadenaron a un normalizador de media cero y varianza unitaria; los demás hiperparámetros se mantuvieron por defecto, con semilla fija, porque el objetivo no era optimizar el desempeño sino comprobar si existía diferencia alguna entre familias de algoritmos.

Los cinco algoritmos recuperan la regla generadora: que un clasificador de vecinos más cercanos iguale a un ensamble de gradiente potenciado, y que ambos iguale a un árbol individual, indica que la frontera de decisión es recuperable por cualquier método, de modo que el problema es separable por construcción. Un árbol de decisión de profundidad cinco reproduce la regla de etiquetado en su totalidad, y la importancia de las características se concentra en dos: la puntuación del producto, con 0.51, y el volumen de ventas, con 0.46, mientras que tres de las siete no contribuyen en absoluto.

El ejercicio vale como **verificación del canal de procesamiento y diagnóstico del conjunto**, no como medida de eficacia. De ello se siguen dos consecuencias. La primera es que estos datos **no permiten discriminar entre algoritmos**: la elección del bosque aleatorio descrita en la Sección III-B responde a requisitos de interpretabilidad y costo, no a una comparación empírica que este conjunto no puede arbitrar. La segunda, más relevante, es que las métricas obtenidas sobre él no estiman la calidad del nivel estimado de riesgo, sino la fidelidad con que un modelo recupera la regla que generó sus propias etiquetas. La validez del enfoque depende de que las características sean legibles en fichas reales y de que las etiquetas provengan de una fuente independiente del vector de entrada, según establece el protocolo de validación de la Sección III-B.

IV-B. Amenazas a la validez

Cuatro limitaciones condicionan lo que este diseño podrá concluir, y conviene explicitarlas antes de su ejecución.

La primera afecta a la capa cliente. La extracción depende de selectores sobre el DOM, y se ha advertido que las técnicas apoyadas en selectores predefinidos son sensibles a cambios de maquetación [20]. Una plataforma que rediseñe su ficha reducirá la cobertura de características sin previo aviso, por

lo que la Fase 1 debe repetirse periódicamente y no tratarse como una medición única.

La segunda afecta al clasificador de riesgo. Sus etiquetas de entrenamiento se derivan mediante reglas deterministas aplicadas a las mismas características que el modelo recibe como entrada, de modo que el desempeño medido sobre ese conjunto refleja la recuperación de esa regla y no el comportamiento frente a vendedores fraudulentos reales. La mitigación es previa a cualquier medición de eficacia y condiciona el orden del trabajo futuro: construir un conjunto cuyas etiquetas provengan de una fuente independiente del vector de características, y hasta entonces no reportar métricas de desempeño del clasificador.

La tercera es de validez ecológica. Un experimento en sesión mide la capacidad de decisión en condiciones de atención deliberada, mientras que la evidencia disponible sugiere que la victimización ocurre justamente cuando esa atención falla [4]. El diseño puede establecer si la herramienta ayuda a quien la mira, no si protege a quien compra distraído. Mitigarlo exige una segunda medición en uso real, con la extensión instalada durante semanas y sobre las compras que el participante hubiera hecho de todos modos, que este protocolo no cubre.

La cuarta es la más general: la arquitectura supone que el atacante no adapta su comportamiento a las características observadas, suposición insostenible a mediano plazo porque los defraudadores ajustan sus estrategias frente a los mecanismos de detección [8]. Como mitigación parcial, el registro de consultas descrito en la Sección III-B hace observable esa deriva y permite reentrenar cuando la distribución de las características cambie; ninguna medición puntual, en cambio, conserva su validez indefinidamente.

V. CONCLUSIONES Y TRABAJO FUTURO

Este trabajo ha presentado el diseño de un sistema que estima el riesgo de estafa en el punto de decisión de compra, a partir de características que el comprador ya tiene delante y sin acceso privilegiado a la plataforma. La contribución principal es el marco conceptual, no una implementación completa: la distinción entre riesgo detectado e información insuficiente, la regla de abstención que la operationaliza y el protocolo de validación que separa la observabilidad de la eficacia. Tres conclusiones se desprenden del diseño.

La primera es que la arquitectura propuesta permite plantear el desplazamiento de la evaluación de riesgo desde el juicio del comprador hacia el sistema sin requerir la cooperación de la plataforma: las ocho características de la Tabla II se derivan del contenido que el navegador ya recibió, lo que distingue la propuesta de la línea dominante en detección de fraude [8]. Que ese desplazamiento resulte además útil para el comprador es lo que el protocolo de validación de la Sección III-B deberá establecer.

La segunda es que la regla de abstención explícita no es un detalle de implementación sino una condición de diseño. Un instrumento que presentara como seguro aquello que solo desconoce trasladaría al comprador un riesgo que no ha

evaluado, y penalizaría a comercios legítimos que simplemente no publicitan sus garantías.

La tercera es que intervenir sobre la información del comprador tiene fundamento teórico y no solo utilidad práctica: la cantidad de reseñas falsas en equilibrio decrece con la fracción de consumidores capaces de interpretar correctamente los indicadores de una ficha [7]. De ese resultado se sigue una implicancia potencial, no una conclusión de este estudio: si la herramienta aumentara esa fracción, su efecto no se agotaría en quien la instala. Comprobarlo exigiría medir el mercado y no al usuario, lo que excede el alcance de este trabajo.

La limitación principal se ha declarado a lo largo del artículo: la arquitectura no ha sido implementada. El único resultado experimental disponible es de naturaleza diagnóstica y apunta contra los propios datos: cinco algoritmos clasifican sin error la partición de prueba, lo que revela que el conjunto es separable por construcción. Las métricas obtenidas sobre él no estiman la calidad de la estimación de riesgo. Lo presentado es un diseño y un protocolo para someterlo a prueba, no un sistema evaluado.

El trabajo futuro tiene un orden obligado, porque cada paso condiciona la interpretación del siguiente. *Primero*, medir qué características resultan legibles en fichas reales, con especial atención al reparto entre plataformas grandes y vendedores independientes. *Segundo*, construir un conjunto de datos cuyas etiquetas provengan de una fuente independiente del vector de entrada; sin él, cualquier métrica seguirá midiendo la regla que generó esas etiquetas. *Tercero*, implementar la arquitectura, incluido el reentrenamiento del clasificador con la veracidad de dominio incorporada. *Cuarto*, evaluar técnicamente los componentes sobre ese conjunto independiente, con el análisis de ablación que establezca cuánto aporta cada característica. *Quinto*, y solo entonces, la evaluación con usuarios, cuyas conclusiones dependen de que los cuatro pasos anteriores estén resueltos.

Una línea distinta es la detección del comportamiento fraudulento del vendedor, que exige evidencia sobre operaciones consumadas y la colaboración de las plataformas; constituye una recomendación para investigaciones posteriores antes que una extensión del sistema aquí descrito.

REFERENCIAS

- [1] J. Aurazo and F. Gasmí, "Digital payment systems in emerging economies: Lessons from Kenya, India, Brazil, and Peru," *Inf. Econ. Policy*, vol. 69, p. 101113, Dec. 2024, doi: 10.1016/j.infoecopol.2024.101113.
- [2] T. N. Tran, L. D. Nghi, and D. T. K. Chinh, "Perceived risk and trust as moderators between online shopping intention and purchase decisions," *Emerg. Sci. J.*, vol. 10, no. 2, pp. 1101–1116, Apr. 2026, doi: 10.28991/ESJ-2026-010-02-026.
- [3] C. Bianchi and M. A. Saleh, "Investigating the drivers of e-commerce continuance intentions among older consumers in Latin America," *J. Internet Commerce*, vol. 23, no. 4, pp. 384–413, 2024, doi: 10.1080/15332861.2024.2424141.
- [4] V. Balakrishnan, U. Ahmed, and F. Basheer, "Personal, environmental and behavioral predictors associated with online fraud victimization among adults," *PLoS ONE*, vol. 20, no. 1, p. e0317232, Jan. 2025, doi: 10.1371/journal.pone.0317232.
- [5] J. M. Whittaker, M. Edwards, C. Cross, and M. Button, "'I have only checked after the event': Consumer approaches to safe online shopping," *Vict. Offender*, vol. 18, no. 7, pp. 1259–1281, 2023, doi: 10.1080/15564886.2022.2130486.
- [6] K. Zhang, H. Wang, M. Chen, X. Chen, L. Liu, Q. Geng, and Y. Zhou, "Leveraging machine learning to proactively identify phishing campaigns before they strike," *J. Big Data*, vol. 12, Art. no. 124, 2025, doi: 10.1186/s40537-025-01174-x.
- [7] Y. Lei, F. Ødegaard, and H. Pun, "Effect of counterfeits and fake reviews in markets for credence goods," *Omega*, vol. 131, p. 103218, Feb. 2025, doi: 10.1016/j.omega.2024.103218.
- [8] T. Lawanna, "An adaptive CBR-agent AI model for detecting fraudulent user behavior in digital marketplace platforms," *J. Intell. Decis. Making Inf. Sci.*, vol. 3, no. 2, pp. 1210–1236, 2026.
- [9] A. S. Rofudin, Orvalamarva, and R. R. Saedudin, "Comparative analysis of information security methods in e-commerce environment," *Int. J. Adv. Sci. Eng. Inf. Technol.*, vol. 15, no. 6, pp. 1740–1746, Dec. 2025.
- [10] A. Mutemi and F. Bacao, "E-commerce fraud detection based on machine learning techniques: Systematic literature review," Sep. 2025, doi: 10.26599/BDMA.2023.9020023.
- [11] A. Janavičiūtė, A. Liutkevičius, G. Dabužinskas, and N. Morkevičius, "Experimental evaluation of possible feature combinations for the detection of fraudulent online shops," *Appl. Sci. (Switzerland)*, vol. 14, no. 2, Jan. 2024, doi: 10.3390/app14020919.
- [12] M. Sánchez-Paniagua, E. Fidalgo, E. Alegre, and F. Jáñez-Martino, "Fraud detection in e-commerce: A comparative analysis of features to enhance machine learning models," *Electron. Commerce Res.*, Apr. 2025, doi: 10.1007/s10660-025-10029-9.
- [13] S. M. Abd-Alhaleem, H. A. Ali, N. F. Soliman, A. D. Algarni, and H. S. Marie, "Advancing e-commerce authenticity: A novel fusion approach based on deep learning and aspect features for detecting false reviews," *IEEE Access*, vol. 12, pp. 116055–116070, 2024, doi: 10.1109/ACCESS.2024.3435916.
- [14] R. Das *et al.*, "Towards the development of an explainable e-commerce fake review index: An attribute analytics approach," *Eur. J. Oper. Res.*, vol. 317, no. 2, pp. 382–400, Sep. 2024, doi: 10.1016/j.ejor.2024.03.008.
- [15] S. A. Rajagukguk and D. Sofyan, "Detecting sophisticated fake reviews on e-commerce platforms using adversarial transformer networks," *Eng. Technol. Appl. Sci. Res.*, vol. 15, no. 6, pp. 29840–29845, Dec. 2025, doi: 10.48084/etasr.13369.
- [16] J. M. Thilini Jayasinghe and S. Dassanayaka, "Detecting deception: Employing deep neural networks for fraudulent review detection on Amazon," *Neural Comput. Appl.*, vol. 37, no. 26, pp. 21715–21742, Sep. 2025, doi: 10.1007/s00521-025-11485-y.
- [17] J. D. Duarte *et al.*, "Machine learning for early detection of phishing URLs in parked domains: An approach applied to a financial institution," *IEEE Access*, vol. 13, pp. 145736–145753, 2025, doi: 10.1109/ACCESS.2025.3599454.
- [18] Y. Jiang and P. Du, "Cross-border e-commerce credit risk early warning model based on deep learning," *Int. J. Reasoning-based Intell. Syst.*, vol. 17, no. 10, pp. 1–9, Aug. 2025, doi: 10.1504/IJRIS.2025.10072955.
- [19] G. Kostopoulos, A. Stefani, V. Vasiliadis, and S. Kotsiantis, "Deep learning for e-commerce: Recent developments in prediction, personalization and decision intelligence," *Appl. Sci.*, vol. 16, Art. no. 2263, Feb. 2026, doi: 10.3390/app16052263.
- [20] P. Landeta-López, J. M. García, C. Guevara-Vega, and A. Ruiz-Cortés, "LLMs applied to web scraping and web crawling: A systematic review," *Computing*, vol. 108, Art. no. 78, May 2026, doi: 10.1007/s00607-026-01666-5.
- [21] J. Brooke, "SUS—A quick and dirty usability scale," in *Usability Evaluation in Industry*, P. W. Jordan, B. Thomas, B. A. Weerdmeester, and I. L. McClelland, Eds. London, U.K.: Taylor & Francis, 1996, pp. 189–194.