

Antes del Click: Análisis de Riesgo del Lado del Cliente para Mitigar Estafas en Compras Digitales

Mathias Alejandro Jave Diaz
Ingeniería de Software
Universidad Peruana de
Ciencias Aplicadas
Lima, Perú
0009-0009-3705-505X

Alex Ramon Alberto Avila Asto
Ingeniería de Software
Universidad Peruana de
Ciencias Aplicadas
Lima, Perú
0009-0008-5624-8482

Fidel Eugenio Garcia Rojas
Ingeniería de Software
Universidad Peruana de
Ciencias Aplicadas
Lima, Perú
0009-0007-4364-0058

Resumen—Los métodos eficaces contra el fraude en el comercio electrónico operan del lado de la plataforma utilizando telemetría interna, dejando al consumidor desprotegido en el momento de decisión. La evidencia indica que la autoconciencia no evita la victimización y que las verificaciones de legitimidad suelen realizarse después de efectuar el pago. Para abordar esta brecha, este artículo propone una arquitectura basada en una extensión de navegador que estima el nivel de riesgo de probabilidad de estafa directamente en el equipo del consumidor. El sistema evalúa ocho características (como la veracidad del dominio y la autenticidad de reseñas) interpretando el documento HTML ya renderizado, sin enviar peticiones adicionales a la plataforma del vendedor. Se incorpora un método de validación que distingue el riesgo detectado de la evidencia insuficiente, asegurando que la falta de información en una ficha de producto nunca se presente como seguridad. La evaluación diagnóstica sobre el conjunto de datos disponible reporta que cinco algoritmos de familias distintas clasifican la partición de prueba sin error y con desviación nula. Este resultado demuestra que el conjunto de datos es separable por construcción, lo cual impide estimar el desempeño algorítmico frente a vendedores fraudulentos reales. Como solución metodológica, el estudio define un diseño experimental estructurado para someter la herramienta a pruebas empíricas de eficacia y usabilidad con usuarios.

Index Terms—comercio electrónico, compras digitales, extensión de navegador, nivel de riesgo de probabilidad de estafas, riesgo del lado del cliente

I. INTRODUCCIÓN

El comercio electrónico peruano opera en un entorno donde la adopción del pago digital no está acompañada por un nivel equivalente de confianza del consumidor. Un análisis comparado de sistemas de pago en economías emergentes reporta que la falta de confianza en las instituciones constituye una barrera clave [18]. Solo el 57 % de los adultos utiliza pagos digitales, frente al 64 % a nivel global. Esta desconfianza genera un impacto directo en el mercado legítimo, ya que la intención y continuidad de compra en canales digitales dependen fuertemente del riesgo percibido por el usuario [19] [20]. La incapacidad de verificar a un vendedor desconocido antes del pago no solo afecta a las víctimas de fraude, sino que impone una fricción comercial sobre los vendedores honestos.

La prevención de estafas en compras digitales depende en gran medida de la capacidad del comprador para evaluar la

fiabilidad del vendedor antes de completar una transacción. Los marcos de protección actuales se sustentan en heurísticas de uso extendido: verificación de la reputación del vendedor, desconfianza hacia precios inverosímiles y comprobación de la dirección del sitio web. El supuesto subyacente es que un comprador informado dispone de los instrumentos necesarios para protegerse.

La evidencia empírica no respalda ese supuesto. Un estudio con una muestra de 820 adultos, replicado sobre una segunda cohorte de 629, demostró que la autoconciencia sobre privacidad digital no predijo significativamente la victimización. La sobreconfianza la incrementó significativamente (razón de momios de 1.437; IC 95 % [1.234, 1.673]), concluyendo que el conocimiento por sí solo no constituye una barrera efectiva contra el fraude [1]. En la misma línea, la verificación del comprador tiende a ocurrir *posterior* a que el pago ya se ha realizado [2].

La eficacia de estas heurísticas se ve comprometida por la pérdida de poder discriminante de los indicadores tradicionales. Los certificados SSL, antes considerados un indicador de fiabilidad, son obtenidos actualmente mediante servicios automatizados [3]. La reputación visible del vendedor ha sido demostrada como manipulable por construcción del mercado [4]. Las dos heurísticas más difundidas la conexión cifrada y la buena puntuación son precisamente las que un defraudador competente puede exhibir legítimamente.

Sin embargo, existen métodos eficaces contra el fraude que operan en un plano inaccesible para el comprador. Los sistemas desplegados por los operadores de plataformas alcanzan desempeños elevados mediante el uso de telemetría interna [5]. Las contramedidas de seguridad revisadas en la literatura se implementan y financian dentro de las organizaciones de comercio [6]. Ninguna de estas soluciones alcanza al comprador que evalúa una ficha en una plataforma o interactúa con un vendedor que no las ha adoptado.

El presente trabajo propone desplazar la evaluación de riesgo desde el juicio subjetivo del comprador hacia un sistema de estimación automática que se ejecute en su navegador, sobre la información que ya tiene disponible y antes de que se efectúe el pago. La pregunta central que se aborda es si un conjunto de características extraíbles del lado del cliente sin acceso

privilegiado a la plataforma y sin recolección automatizada de datos resulta suficiente para generar una advertencia útil en el punto de decisión.

Una advertencia se considera útil si cumple tres condiciones: (1) se genera antes de que el pago se efectúe, (2) se basa en al menos cuatro características verificables, y (3) distingue explícitamente entre riesgo detectado e información insuficiente. Esta última condición es crítica: un sistema que presentara como seguro aquello que solo desconoce trasladaría al comprador un riesgo que no ha evaluado.

El alcance de este sistema se delimita a la estimación probabilística del nivel de riesgo de un vendedor mediante una escala ordinal, excluyendo la emisión de un dictamen categórico de fraude. Esta distinción tiene dos implicaciones operativas. Por un lado, admite declaraciones explícitas de insuficiencia de evidencia en lugar de forzar decisiones binarias. Por otro, el sistema se evalúa en función de la mitigación de riesgo y la reducción de advertencias infundadas, en lugar de utilizar métricas de clasificación estándar contra una verdad de referencia inexistente en la ficha de producto.

Las contribuciones de este trabajo son tres. En primer lugar, un conjunto de ocho características de riesgo extraíbles desde el cliente. Estas características vienen acompañadas de una regla explícita que distingue el riesgo detectado de la evidencia insuficiente, garantizando que la ausencia de información nunca se presente como seguridad. Esta distinción constituye una contribución conceptual al campo: los sistemas de detección de fraude existentes operan sobre datos completos y no abordan el problema de la información parcial que enfrenta el comprador. En segundo lugar, una arquitectura de tres capas cuyo componente principal es una extensión de navegador. Se presentan los diseños de los módulos clave y se entrenaron prototipos de los clasificadores de vendedor y reseñas. En tercer lugar, un protocolo de validación en dos fases que separa la observabilidad de las características de la eficacia del veredicto, identificando las amenazas a la validez que condicionan las conclusiones.

Cabe precisar que la extensión de navegador y el analizador de dominio no han sido implementados; los clasificadores han sido entrenados sobre datos sintéticos cuyas limitaciones se analizan en la Sección IV. El presente trabajo es, por tanto, una propuesta arquitectónica con componentes parcialmente validados, no un sistema completo evaluado.

El resto del artículo se organiza de la siguiente manera. La Sección II revisa el trabajo relacionado; la Sección III detalla la arquitectura propuesta; la Sección IV describe el protocolo de validación; la Sección V presenta las conclusiones y el trabajo futuro.

II. TRABAJO RELACIONADO

La estimación de riesgo en comercio electrónico constituye un campo de investigación consolidado. Esta sección lo analiza en cinco dimensiones: inteligencia artificial para estimación de riesgo, detección de vendedores fraudulentos desde la plataforma, identificación de reseñas manipuladas, detección de sitios de suplantación y contramedidas implementadas por

las organizaciones comerciales. Un apartado final identifica la brecha que este trabajo aborda. Los avances se concentran en el lado del operador de la plataforma, y rara vez llegan al comprador en el momento de la decisión de compra.

1. *Inteligencia artificial aplicada a la estimación de riesgo*

El aprendizaje profundo se ha consolidado como la tecnología preferida para tareas como estimación de riesgo y toma de decisiones en plataformas de comercio electrónico [7]. Los sistemas basados en reglas no escalan ante el volumen y el carácter adaptativo de las amenazas actuales. El contenido generado por usuarios como reseñas, calificaciones e imágenes resulta decisivo en la decisión de compra y, simultáneamente, altamente vulnerable a la manipulación y al fraude coordinado.

Un ejemplo cuantificado ilustra tanto el nivel alcanzado como las condiciones que lo hacen posible. Un modelo híbrido de red convolucional con máquina de soporte vectorial optimizada alcanza una exactitud del 96.23 % y un AUC de 0.9118 al clasificar el riesgo crediticio de empresas de comercio transfronterizo [8]. Sin embargo, el objeto estimado no es el nivel de riesgo de estafa que percibe un comprador individual. Los insumos que ese desempeño requiere información financiera de la contraparte, condiciones de operación y evaluaciones de la plataforma no son accesibles desde el navegador de quien está por realizar una compra [8].

Los algoritmos que sustentan esta línea de investigación son identificables. En la detección de reseñas manipuladas predominan los modelos de lenguaje basados en transformadores: variantes de BERT ajustadas al dominio del comercio electrónico [9], arquitecturas adversariales sobre la misma familia [10] y redes neuronales profundas aplicadas a reseñas de plataformas concretas [11]. En ocasiones se combinan con memorias de largo y corto plazo bidireccionales y con herramientas de explicabilidad para justificar el veredicto [9]. En la estimación de riesgo del vendedor y en la detección de sitios de suplantación predominan, en cambio, los métodos de ensamble y los clasificadores de margen: bosques aleatorios, máquinas de soporte vectorial, árboles de decisión y gradiente potenciado aparecen de forma recurrente [12]–[14]. El marco de detección más reciente combina cuatro de ellos con selección de características mediante SHAP y eliminación recursiva [3]. Esta distribución no es casual: el texto libre de las reseñas exige representaciones contextuales, mientras que los atributos estructurales de una ficha heterogéneos y de baja dimensionalidad se ajustan mejor a los métodos basados en árboles.

Estos enfoques se sitúan invariablemente en la plataforma, en la institución financiera o en el operador del servicio, que son quienes disponen de los registros y ejecutan los modelos. Incluso en esos entornos admiten limitaciones: los detectores más avanzados pueden ser eludidos mediante perturbaciones adversariales u ofuscación lingüística [7]. La defensa centralizada, por sólida que sea, deja pasar casos que alcanzan al comprador sin que este disponga de instrumento alguno de protección.

2. Detección de fraude desde la plataforma

La detección de fraude en comercio electrónico ha alcanzado madurez metodológica [12]. Un exponente reciente combina razonamiento basado en casos con un sistema multiagente para alcanzar un AUC de 0.979 sobre 1.27 millones de instancias, resistiendo la deriva del comportamiento fraudulento [5]. Dicho desempeño se sostiene sobre datos que solo el operador posee: registros transaccionales, huellas de dispositivo y un grafo de interacción de el comprador que evalúa una ficha no tiene acceso.

3. Reseñas manipuladas

La segunda línea de investigación aborda la autenticidad de las reseñas. Además de los detectores basados en contenido textual, esta línea incorpora enfoques de fusión que combinan diversas características de la reseña [16]. Un modelo de competencia demuestra que en equilibrio el vendedor auténtico no adquiere reseñas falsas mientras que el falsificador puede hacerlo para inducir a error al comprador [4]. La manipulación de la reputación no es, por tanto, una anomalía sino un comportamiento previsible. La cantidad de reseñas falsas en equilibrio decrece con la fracción de consumidores capaces de interpretar correctamente los indicadores de la ficha. Esto sitúa la información del comprador y no solo la capacidad de detección de la plataforma como palanca de mitigación efectiva.

4. Suplantación de sitios y análisis de dominio

La tercera línea proviene de la seguridad informática. En [17] se detectan localizadores uniformes de recursos (URL) de *phishing* en dominios aparcados a partir de características derivadas del registro, aplicándolo a una institución financiera; en [3] se propone un marco de detección sobre 1 353 URL con selección de características por explicaciones aditivas de Shapley (SHAP) y eliminación recursiva, alcanzando una exactitud del 98.4 %.

Lo más relevante de este último para el presente trabajo no es el desempeño del clasificador sino el diagnóstico que lo motiva: el certificado SSL válido dejó de discriminar sitios legítimos de fraudulentos. Los atacantes obtienen certificados mediante servicios automatizados, y las listas de bloqueo del navegador no alcanzan a cubrir dominios desplegados y retirados en horas [3].

5. Contramedidas del lado del comercio

Una revisión sistemática de métodos de seguridad en comercio electrónico [6] inventaría siete familias de controles y concluye que ninguna basta por sí sola, por lo que la defensa debe articularse en capas. Las siete, no obstante, se implementan y financian dentro de la organización comercial. Ninguna protege al comprador que interactúa con una plataforma o un vendedor que no las ha adoptado.

6. Brecha de investigación

El comprador ocupa una posición singular: existen métodos eficaces contra vendedores fraudulentos, reseñas manipuladas y suplantación de sitios, pero todos requieren datos, infraestructura o autoridad de los que él carece. Las recomendaciones dirigidas a él son de naturaleza educativa y de eficacia limitada [1], [2]. Ninguno de los trabajos revisados combina características de dominio, de vendedor y de reseñas en un instrumento que se ejecute del lado del comprador y emita su advertencia antes del pago. Esa es la brecha que este trabajo aborda. Las características propuestas son trasladables a cualquier plataforma de comercio electrónico que exponga fichas de producto con información pública: MercadoLibre, Amazon, eBay o AliExpress, entre otras.

III. MÉTODO

Esta sección utiliza la siguiente terminología:

- *Extensión*: aplicación de navegador que extrae características del DOM.
- *Motor de riesgo*: conjunto de servicios que estiman el nivel de riesgo (excluye persistencia).
- *Sistema*: la arquitectura completa (extensión + motor de riesgo + persistencia).

La unidad de análisis es una *ficha de producto* que el comprador tiene abierta en su navegador: el sistema no recorre catálogos ni consulta interfaces privilegiadas de la plataforma, sino que opera sobre la misma información que el comprador ya tiene delante. Esta restricción gobierna todas las decisiones de diseño que siguen. Separa esta propuesta de los sistemas de detección desplegados por el operador del comercio [5].

1. Características extraíbles del lado del cliente

Para los efectos de esta arquitectura, se define como *característica extraíble del lado del cliente* a todo atributo de una publicación que cumpla tres condiciones simultáneas: ser visible para el comprador antes del pago, residir en el documento ya entregado al navegador y no requerir acceso a interfaces internas de la plataforma. La puntuación del producto, el número de reseñas y el nombre de dominio cumplen estrictamente con estos criterios.

Esta distinción separa el presente trabajo de la línea dominante en detección de fraude, cuya dependencia de telemetría interna ya mencionada. El comprador dispone de un conjunto de características restringido, por lo que la pregunta central que este trabajo aborda es si dichos datos accesibles resultan suficientes para producir una advertencia útil.

2. Lectura del DOM y recolección automatizada

La operación que realiza la extensión requiere una caracterización precisa. Una revisión sistemática define el *web scraping* y el *web crawling* como el proceso automatizado de extracción de datos en el que las herramientas navegan a través de múltiples páginas [21]. La extensión propuesta no realiza ninguna de las dos operaciones: no navega, porque es el usuario quien decide qué ficha abrir; no recorre múltiples páginas, porque opera sobre el documento que el navegador

ya renderizó. Su operación consiste en interpretar contenido que ya le había sido entregado.

Esta caracterización acota también las limitaciones del enfoque. La misma revisión advierte que las herramientas apoyadas en selectores predefinidos son susceptibles a cambios de maquetación, y que entre los desafíos del área figuran los riesgos legales [21]. La primera observación se declara como amenaza a la validez más adelante. La segunda es la razón para no retransmitir contenido de la plataforma más allá de las características que el veredicto requiere.

3. Protección de pago declarada

Las plataformas de comercio de mayor tamaño publican esquemas mediante los cuales retienen el pago hasta la conformidad del comprador o garantizan su devolución ante incumplimiento. Dicha declaración constituye un compromiso público y verificable en la propia ficha. Representa por ello una característica legítima.

Su ausencia, en cambio, no es igualmente informativa: un vendedor independiente puede ofrecer condiciones equivalentes sin anunciarlas, o anunciarlas donde la extensión no alcanza a leer. Tratar el silencio como evidencia de inseguridad convertiría una limitación del observador en una acusación sobre el observado. Esto es tanto más problemático cuanto que las contramedidas disponibles se despliegan y financian del lado del comercio [6]. Su ausencia visible correlaciona con el tamaño del vendedor antes que con su honestidad.

La arquitectura se organiza en tres capas (cliente, motor de riesgo y persistencia) y se detalla más adelante. La separación en tres capas responde a la necesidad de desacoplar la observación del DOM (que debe ejecutarse en el cliente por razones de privacidad y eficiencia) del análisis de riesgo (que requiere acceso a servicios externos) y de la persistencia (que debe garantizar la trazabilidad sin exponer datos sensibles). Esta separación permite escalar cada componente de forma independiente. Facilita la sustitución de algoritmos de clasificación sin modificar la capa de observación.

4. Capa cliente: observación sin recolección automatizada

La capa cliente se implementa como una *aplicación nativa en el navegador* (una extensión) que se activa cuando el usuario abre una ficha de producto en una plataforma soportada. La extensión recorre el árbol DOM ya renderizado, localiza mediante selectores los elementos que exponen los atributos de interés precio, puntuación, número de reseñas, identidad del vendedor, medios de pago anunciados, políticas de garantía y construye un vector de observaciones que envía al motor de riesgo. La extensión constituye el componente principal de esta propuesta, y no por conveniencia de implementación. Es el único punto del sistema que coincide, en espacio y en tiempo, con el instante en que el comprador decide. Se ejecuta sobre la ficha que él tiene abierta, sin mediación de la plataforma y antes de que el pago ocurra. Ningún otro componente de esta arquitectura coincide de ese modo con el instante de la decisión.

TABLA I
CONJUNTO DE CARACTERÍSTICAS, ORIGEN Y COMPORTAMIENTO ANTE EVIDENCIA AUSENTE

Característica	Se computa en	Valores	Si no hay evidencia
Protección de pago declarada	Cliente	declarada / no declarada	<i>no verificable</i>
Veracidad de dominio	Backend	escala ordinal	<i>no verificable</i>
Reputación del vendedor	Backend	escala ordinal	<i>no verificable</i>
Autenticidad de reseñas	Backend	proporción estimada	<i>no verificable</i>
Puntuación del producto	Cliente	continua	ausente
Presencia de reseñas	Cliente	binaria	ausente
Políticas de garantía	Cliente	ordinal	<i>no verificable</i>
Volumen de ventas	Cliente	entero	ausente

El flujo de operación de la capa cliente se resume en cuatro pasos: (1) el usuario abre una ficha de producto; (2) la extensión detecta la carga y extrae características del DOM; (3) construye un vector de observaciones; y (4) envía el vector al motor de riesgo mediante petición HTTP segura. La extensión no almacena datos sensibles del usuario.

Un cliente complementario consume el mismo servicio y cubre la compra que ocurre fuera del navegador de escritorio. Opera sobre lo que el usuario le proporciona, sin acceso al documento renderizado, de modo que resolverá menos características.

Esta capa existe porque la advertencia que ha de llegar antes del pago debe producirla el sistema y no el juicio del comprador [1], [2]. La ventaja técnica es que la información necesaria ya fue entregada al navegador. El sistema no emite hacia la plataforma del vendedor ninguna petición que el comprador no hubiera cursado en cualquier caso.

«Del lado del cliente» no significa, sin embargo, «sin servidor»: el vector observado viaja al motor de riesgo, el analizador de dominio consulta servicios de registro, y cada consulta queda registrada. La propuesta elimina la dependencia respecto de la plataforma del vendedor a costa de introducir un nuevo tercero de confianza, con la política de retención y anonimización que ello exige. Su otra contrapartida es la fragilidad ante cambios de maquetación [21].

5. Conjunto de características y regla de abstención ante evidencia ausente

El motor de riesgo trabaja sobre ocho características, resumidas en la tabla de características. Cada característica se define junto con la capa que la computa, su dominio de valores y de manera central para esta propuesta el valor que toma cuando no puede determinarse.

La *protección de pago declarada* fija el criterio que rige al resto. Plataformas como MercadoLibre, Amazon o AliExpress declaran en la ficha que retienen el pago o que garantizan la

devolución ante incumplimiento, y la extensión detecta esa declaración; cuando no la encuentra, el sistema no infiere que el pago sea inseguro sino que registra la característica como *no verificable*, según la distinción establecida en la subsección anterior.

Esta regla se aplica de manera uniforme: para toda característica se distingue entre valor conocido, valor ausente por no aplicar y valor indeterminado por falta de evidencia. Una característica se considera *resuelta* cuando toma un valor conocido; los otros dos estados la dejan sin resolver, y la tabla de características indica cuál adopta cada una cuando la ficha no aporta evidencia. El agregador propaga esa distinción hasta el veredicto mediante dos condiciones que deben cumplirse conjuntamente.

La primera es de cobertura. Sea r el número de características resueltas de las ocho; el sistema exige $r \geq 4$. El umbral mínimo se estableció para garantizar al menos una característica por dimensión de riesgo (tres dimensiones) más una redundancia. Un umbral de tres podría satisfacer la condición dimensional sin margen de error; uno de cinco reduciría excesivamente los casos en que el sistema puede emitir un veredicto. La segunda es de suficiencia por dimensión. Las ocho características cubren tres dimensiones de riesgo distintas: la identidad del sitio (veracidad de dominio), la fiabilidad del vendedor (reputación, volumen de ventas, políticas de garantía y protección de pago declarada) y la evidencia de la comunidad (puntuación, presencia y autenticidad de reseñas). El sistema exige que al menos una característica de cada dimensión se haya resuelto.

La elección de ocho características se justifica por la necesidad de cubrir las tres dimensiones con al menos dos indicadores por dimensión, lo que permite detectar inconsistencias y reducir la influencia de valores atípicos. Un conjunto menor limitaría la capacidad de discriminación; uno mayor aumentaría la complejidad de extracción sin beneficio proporcional en la precisión del veredicto, dada la información disponible en el lado del cliente.

Cuando ambas condiciones se satisfacen, el veredicto se emite con un nivel de confianza derivado de la cobertura: alta si $r \geq 6$, media en caso contrario. Cuando alguna falla, el sistema no emite riesgo sino *evidencia insuficiente*, junto con la lista de características que no pudo resolver.

La segunda condición distingue esta regla de un simple conteo: un umbral global trataría por igual la pérdida de tres características redundantes y la de la única que informa sobre la identidad del sitio, dejando al comprador sin protección frente a la suplantación. La justificación de fondo es la asimetría de costos: presentar como seguro aquello que solo es desconocido traslada al comprador un riesgo que el sistema no ha evaluado.

6. Descomposición en servicios

El motor de riesgo de la Fig. 1 no es un bloque único: se despliega en cuatro servicios desacoplados. Un analizador de veracidad de dominio verifica la legitimidad del sitio web consultando registros DNS y patrones morfológicos; un analizador

TABLA II
COMPONENTES DE LA ARQUITECTURA Y SUS FUNCIONES PRINCIPALES

Componente	Capa	Función
Ficha de Producto	Cliente	Fuente de datos (DOM renderizado)
Extensión de navegador	Cliente	Extrae 8 características del DOM
Aplicación web	Cliente	Autenticación y acceso a servicios
API centralizadora	Motor de riesgo	Recibe, delega y agrega resultados
Analizador de dominio	Motor de riesgo	Verifica veracidad del sitio web
Analizador de reputación	Motor de riesgo	Evalúa historial del vendedor
API de estimación de riesgo	Motor de riesgo	Calcula probabilidad de estafa
API de detección de reseñas	Motor de riesgo	Identifica contenido fraudulento
Base de Datos	Persistencia	Almacena para trazabilidad y reentrenamiento

de reputación evalúa el historial y las políticas del vendedor; una API de estimación de riesgo calcula la probabilidad de estafa mediante un bosque aleatorio; y una API de detección de reseñas falsas identifica contenido potencialmente fraudulento mediante un modelo DistilBERT. La API centralizadora recibe las observaciones de la extensión, delega las características relevantes a los cuatro servicios y agrega los resultados para emitir el veredicto. La persistencia se resuelve sobre una base relacional que almacena las consultas y sus resultados para trazabilidad y reentrenamiento. La separación responde a una propiedad que el sistema necesita: cada servicio puede actualizarse de forma independiente cuando cambian las características disponibles o los patrones lingüísticos del fraude, sin interrumpir el servicio ni versionar la interfaz que consume la extensión.

El flujo de operación del motor de riesgo se resume en cuatro pasos: (1) la API centralizadora recibe el vector de observaciones de la extensión; (2) delega las características relevantes a los cuatro servicios; (3) cada servicio procesa de forma independiente y en paralelo; y (4) la API centralizadora combina los resultados y almacena la consulta en la base de datos. Esta separación permite escalar horizontalmente cada componente según la carga.

7. Analizador de veracidad de dominio

El analizador de dominio recibe el nombre de host de la ficha y devuelve una estimación ordinal de veracidad. Su entrada se compone de atributos del registro del dominio, de la cadena de resolución incluidos los registros de nombre canónico (CNAME) y de la coincidencia con patrones morfológicos asociados a campañas de suplantación.

Este módulo es necesario porque ni el certificado SSL ni las listas de bloqueo del navegador discriminan ya la suplantación [3]. La ventaja de analizar registro y resolución en lugar de contenido es que estos atributos son costosos de falsificar. Se




Fig. 1. Arquitectura lógica propuesta. La capa cliente (extensión de navegador) extrae características del DOM renderizado y las envía a la API centralizadora del motor de riesgo. El motor de riesgo se descompone en cuatro servicios: un analizador de veracidad de dominio, un analizador de reputación, una API de estimación de riesgo y una API de detección de reseñas falsas. La API centralizadora agrega los resultados y almacena las consultas en la capa de persistencia para trazabilidad y reentrenamiento.

TABLA III
CONFIGURACIÓN DEL CLASIFICADOR DE RIESGO DEL VENDEDOR

Parámetro	Valor
Algoritmo	Bosque aleatorio
Número de árboles	100
Variables de entrada	7
Clases	Riesgo alto / moderado / bajo
Registros	10 000
Distribución de clases	3 333 / 3 334 / 3 333
Partición entrenamiento-prueba	80 / 20
Semilla	42

ha mostrado que características derivadas del registro permiten detectar URL de *phishing* en dominios aparcados [17], lo que sostiene la viabilidad del enfoque sobre esta clase de atributos. El módulo no reemplaza la comprobación de certificado, que la literatura de seguridad en comercio electrónico caracteriza como el control fundacional y de menor costo [6], sino que la complementa en la dimensión donde aquella dejó de ser informativa.

El flujo de operación del analizador de dominio se resume en tres pasos: (1) recibe el nombre de host de la extensión; (2) consulta servicios de registro y resolución de nombres para obtener atributos del dominio; y (3) aplica reglas de clasificación para emitir una estimación ordinal de veracidad (alta, media o baja). El módulo opera de forma asincrónica y no bloquea la emisión del veredicto principal.

8. Modelos de inferencia sobre vendedor y reseñas

Dos componentes de aprendizaje automático completan el motor. El primero estima el riesgo del vendedor a partir del vector de características extraídas y devuelve un nivel ordinal; el segundo estima la proporción de reseñas presumiblemente fraudulentas en la ficha. Sus configuraciones se resumen en las Tablas III y IV.

Para la estimación de riesgo del vendedor se emplea un bosque aleatorio y no una arquitectura de mayor capacidad, por tres propiedades que el problema exige. La dimensionalidad: el vector de entrada contiene ocho características heterogéneas binarias, categóricas, discretas y continuas, un régimen en el que los métodos de ensamble por árboles operan sin normalización ni codificaciones adicionales. La interpretabilidad: el modelo expone la contribución relativa de cada característica, con la que se construye la explicación que acompaña al veredicto. Y el costo: la inferencia sobre cien árboles es despreciable frente a la latencia de red de la consulta.

El clasificador del que se dispone actualmente difiere de esta especificación: fue entrenado sobre siete entradas, sin la veracidad de dominio que este trabajo incorpora. Añadirle exige reentrenar el modelo sobre un conjunto que la contenga, y su ausencia es consecuencia de que este trabajo describe la arquitectura propuesta y no una implementación ya construida.

El segundo componente estima la autenticidad de las reseñas con DistilBERT, un codificador transformador destilado cuya

configuración de ajuste recoge la tabla de configuración. La elección de una variante destilada responde a una restricción operativa: la inferencia ocurre entre la consulta de la extensión y la emisión del veredicto, de modo que su costo incide sobre el tiempo que el comprador espera. Seis capas y 66.96 millones de parámetros reducen ese costo frente a un codificador completo; la ejecución en precisión de 32 bits sobre unidad central de proceso evita exigir aceleración por hardware. La contrapartida es una capacidad de representación menor, cuya repercusión sobre la exactitud debe cuantificarse en la validación.

El ajuste fino se realizó durante una época con tasa de aprendizaje de 2×10^{-5} y planificador lineal, valores habituales para adaptar un codificador preentrenado sin alterar las representaciones aprendidas. La entrada del clasificador no es únicamente el texto de la reseña: se serializan conjuntamente la categoría del producto, la calificación asignada y el texto, de modo que el modelo dispone del contexto en el que la reseña fue emitida. Esta decisión responde a que una misma formulación puede resultar verosímil o anómala según la calificación que la acompaña. La brevedad del ajuste una sola época constituye una limitación que la Sección IV recoge. Este trabajo no evalúa el clasificador de reseñas: la tabla de configuración documenta su configuración para hacer reproducible el componente. Ni el corpus de ajuste ni sus métricas de prueba forman parte de lo reportado aquí, y su evaluación queda comprendida en el trabajo futuro de la Sección V.

La inferencia sobre reseñas es necesaria porque, según el resultado de equilibrio citado en la Sección II, la reputación visible es manipulable por construcción [4]: tomar la puntuación agregada como indicador de confianza coincide con el comportamiento que el vendedor fraudulento busca inducir. La arquitectura incorpora por ello la estimación de autenticidad de las reseñas como característica independiente de la puntuación, si bien la forma en que ambas deben combinarse y en particular si la segunda debe corregir a la primera antes de la clasificación constituye una decisión de diseño abierta que la validación deberá resolver.

9. Agregación, presentación y persistencia

El agregador combina las características resueltas en un veredicto con cuatro desenlaces posibles: riesgo alto, moderado o bajo cuando la evidencia disponible permite decidir, y *evidencia insuficiente* cuando no. Los tres primeros se acompañan del nivel de confianza y de la lista de características que los sustentan; el cuarto, de las características que no pudieron resolverse. La presentación es deliberadamente explicativa: junto al veredicto se muestra qué características se verificaron, cuáles quedaron indeterminadas y qué acredita cada una, conforme al requisito de trazabilidad que la literatura de detección de fraude ha ido incorporando frente a los clasificadores opacos [5].

La interfaz extiende el botón estándar del navegador. Al hacer clic, el usuario visualiza: (1) un indicador de color con el veredicto (rojo para riesgo alto, amarillo para moderado,

TABLA IV
CONFIGURACIÓN DEL CLASIFICADOR DE RESEÑAS FRAUDULENTAS

Arquitectura		Ajuste fino	
Modelo base	DistilBERT	Optimizador	AdamW <i>fused</i>
Cabezal	Clasif. de secuencias	Tasa de aprendizaje	2×10^{-5}
Capas del codificador	6	Planificador	Lineal, sin calentamiento
Cabezas de atención	12	Decaimiento de pesos	0.01
Dimensión de representación	768	$\beta_1, \beta_2, \epsilon$	0.9, 0.999, 10^{-8}
Dimensión <i>feed-forward</i>	3072	Recorte de gradiente	1.0
Parámetros	66.96 M (FP32)	Tamaño de lote (entr./eval.)	16 / 16
Activación	GELU	Acumulación de gradiente	1
<i>Dropout</i> gen./aten./clasif.	0.1 / 0.1 / 0.2	Épocas	1
Longitud máx. de secuencia	512 <i>tokens</i>	Precisión numérica	FP32
Tamaño de vocabulario	30 522	Evaluación	Por época
Clases	REAL, FAKE	Semilla	42

verde para bajo, gris para evidencia insuficiente); (2) la lista de características verificadas con su valor individual; (3) las características no resueltas y la razón de la falla; y (4) un botón para acceder al registro de la consulta.

Finalmente, cada consulta se registra en una base de datos junto con las características extraídas y el veredicto emitido. El registro habilita la trazabilidad de cada advertencia y constituye el conjunto de datos con el que los modelos se reentrenarán. La Sección IV fija los términos de retención y anonimización.

IV. VALIDACIÓN

Esta sección describe el protocolo con el que se someterá a prueba la arquitectura completa. El sistema se considera exitoso si cumple tres condiciones: (1) la extensión resuelve al menos el 70 % de las características en fichas de plataformas grandes y al menos el 40 % en vendedores independientes; (2) la tasa de falsos positivos no supera el 15 %, para evitar que la herramienta pierda credibilidad o imponga costos injustificados sobre comercios honestos; y (3) al menos el 60 % de los participantes reporta que la advertencia influyó en su decisión de compra. Estos umbrales se fijan en función de la literatura sobre aceptación de sistemas de recomendación [22]. Se revisarán tras la Fase 1.

1. Verificación preliminar del vector de características

Para verificar que el vector de ocho características de la tabla de características contiene información discriminante, se construyó un conjunto sintético de 10 000 registros con tres clases equilibradas. El conjunto se construyó ante la ausencia de un conjunto etiquetado público de fichas de vendedores peruanos: sus variables y rangos se derivaron de los factores de riesgo identificados en la Sección II, y las etiquetas se asignaron mediante reglas deterministas sobre esas mismas variables. Declarar esta procedencia es indispensable para interpretar lo que sigue. Sus siete entradas corresponden a siete de las ocho de la tabla de características. La veracidad de dominio, que este trabajo introduce, es la única que no forma parte de ese vector. Se entrenaron cinco algoritmos de familias distintas sobre la misma partición 80/20 con semilla fija, y

se validaron además mediante validación cruzada estratificada de cinco pliegues sobre el conjunto completo. Los resultados muestran que los cinco algoritmos clasifican correctamente los 2 000 registros de prueba, sin desviación entre pliegues.

Los experimentos se ejecutaron en un entorno estandarizado para garantizar su reproducibilidad: Ubuntu 24.04.3 LTS, Python 3.11, scikit-learn, NumPy y pandas. El hardware consistió en un servidor con procesador Intel Xeon E3-1240 v5 (4 núcleos, 8 hilos, 3.90 GHz), ejecutados íntegramente en CPU. Las máquinas de soporte vectorial y el clasificador de vecinos más cercanos se encadenaron a un normalizador de media cero y varianza unitaria. Los demás hiperparámetros se mantuvieron en sus valores por defecto, con semilla fija en todos los casos: el objetivo no era optimizar el desempeño sino comprobar si existía diferencia alguna entre familias de algoritmos.

Los cinco algoritmos clasifican correctamente los 2 000 registros de prueba, sin desviación entre pliegues. El resultado no debe leerse como evidencia de la calidad de ninguno de ellos. Que un clasificador de vecinos más cercanos iguale a un ensamble de gradiente potenciado, y que ambos igualen a un árbol individual, indica que la frontera de decisión es recuperable por cualquier método. El problema es separable por construcción. Un árbol de decisión de profundidad cinco reproduce la regla de etiquetado en su totalidad, y la importancia de las características se concentra en dos: la puntuación del producto, con 0.51, y el volumen de ventas, con 0.46. Mientras tanto, tres de las siete no contribuyen en absoluto.

De ello se siguen dos consecuencias. La primera es que este conjunto **no permite discriminar entre algoritmos**: la elección del bosque aleatorio descrita en la Sección III se sostiene en sus propiedades de interpretabilidad y costo, no en una comparación empírica que estos datos no pueden arbitrar. La segunda, más relevante, es que las métricas obtenidas sobre él no estiman la calidad del nivel de riesgo asignado, sino la fidelidad con que un modelo recupera la regla que generó sus propias etiquetas. La verificación confirma que el vector de características contiene información discriminante, pero la validez del enfoque depende de que las características sean legibles en fichas reales. Depende también de que las

etiquetas provengan de una fuente independiente, como se describe en el protocolo de la siguiente subsección. Esta verificación preliminar es, por tanto, un prerequisite para cualquier evaluación posterior, no una métrica de calidad del sistema.

2. Diseño experimental de la validación

La validación se ejecutará en el Perú, sobre las plataformas y los hábitos descritos en la Sección IV. Esa elección delimita el alcance de las conclusiones empíricas, no el de la arquitectura: las características de la tabla de características se derivan de elementos presentes en cualquier ficha de producto y no de particularidades del mercado peruano. La propuesta es trasladable a otros contextos, con la salvedad de que la cobertura efectiva de cada característica debe volver a medirse en cada mercado.

La validación se organiza en dos fases con objetivos separables.

Fase 1: observabilidad de las características. Antes de evaluar la utilidad del veredicto es necesario establecer qué fracción de las características de la tabla de características resulta efectivamente legible en fichas reales. Sobre una muestra de fichas de producto de las plataformas de mayor uso en el Perú se registrará, para cada característica, si pudo resolverse o si quedó indeterminada, distinguiendo entre plataformas grandes y vendedores independientes. El desenlace relevante no es un porcentaje agregado sino su distribución: una arquitectura que solo resolviera características en las plataformas que ya ofrecen garantías carecería de utilidad precisamente en el segmento donde el riesgo se concentra.

Fase 2: eficacia con usuarios. Un diseño con dos grupos con y sin la extensión activa enfrentará a los participantes a un conjunto de fichas preparadas que incluya casos legítimos y casos con indicadores de fraude. La población objetivo son compradores digitales peruanos de entre 18 y 60 años, con una muestra prevista de cincuenta participantes que otorgarán su consentimiento de forma voluntaria antes de comenzar. Las sesiones se conducirán de manera presencial o en línea, según la disponibilidad de cada participante. Los registros de consulta descritos en la Sección III se recogerán disociados del participante que los originó, se conservarán únicamente durante el periodo de análisis y se eliminarán al cierre del estudio; ningún dato que permita reconstruir el historial de compra de una persona identificada forma parte de lo que el protocolo almacena.

Del comportamiento observado durante la sesión se medirá la tasa de identificación correcta, la tasa de falsos positivos sobre comercios legítimos y el tiempo hasta la decisión. La percepción del participante se recoge mediante un cuestionario estructurado de quince ítems con respuesta en escala de Likert de cinco puntos, organizado en cinco dimensiones [22]. La eficacia se juzga por las tres primeras medidas de comportamiento, y la aceptación, por las dos últimas dimensiones del cuestionario.

La tasa de falsos positivos es la métrica que gobierna el diseño. Un instrumento que advierte con excesiva frecuencia

TABLA V
DIMENSIONES DEL INSTRUMENTO DE VALIDACIÓN CON USUARIOS

Dimensión	Qué establece
Usabilidad	Si el veredicto y su explicación se interpretan sin instrucción previa (bloque SUS)
Confianza percibida	Si el participante considera fundada la advertencia que recibe
Riesgo percibido	Si su estimación del riesgo de la ficha varía al disponer de la herramienta
Intención de uso y recomendación	Si declararía seguir usándola fuera del entorno de prueba
Influencia en la decisión	Si la advertencia modificó lo que habría hecho sin ella

pierde credibilidad; su costo recae sobre comercios honestos. Por ello la regla de abstención de la Sección III distingue el veredicto de riesgo del de evidencia insuficiente: son errores distintos y deben medirse por separado.

3. Amenazas a la validez

Cuatro limitaciones condicionan lo que este diseño podrá concluir, y conviene explicitarlas antes de su ejecución.

La primera afecta a la capa cliente. La extracción depende de selectores sobre el DOM, y se ha advertido que las técnicas apoyadas en selectores predefinidos son sensibles a cambios de maquetación [21]. Una plataforma que rediseñe su ficha reducirá la cobertura de características sin previo aviso, por lo que la Fase 1 debe repetirse periódicamente y no tratarse como una medición única.

La segunda afecta al clasificador de riesgo. Sus etiquetas de entrenamiento se derivan mediante reglas deterministas aplicadas a las mismas características que el modelo recibe como entrada, de modo que el desempeño medido sobre ese conjunto refleja la recuperación de esa regla y no el comportamiento frente a vendedores fraudulentos reales. Su evaluación exige, por tanto, un conjunto de datos con etiquetas de origen independiente del vector de características.

La tercera es de validez ecológica. Un experimento con fichas preparadas mide la capacidad de detección en condiciones de atención deliberada, mientras que la evidencia disponible sugiere que la victimización ocurre justamente cuando esa atención falla [1]. El diseño puede establecer si la herramienta ayuda a quien la mira, no si protege a quien compra distraído.

La cuarta es la más general: la arquitectura supone que el atacante no adapta su comportamiento a las características observadas, suposición insostenible a mediano plazo porque los defraudadores ajustan sus estrategias frente a los mecanismos de detección [5]. El registro de consultas descrito en la Sección III existe para hacer observable esa deriva.

V. CONCLUSIONES Y TRABAJO FUTURO

Este trabajo ha presentado el diseño de un sistema que estima el riesgo de estafa en el punto de decisión de compra, a partir de características que el comprador ya tiene delante y sin acceso privilegiado a la plataforma. La contribución principal es el marco conceptual, no una implementación completa: la

distinción entre riesgo detectado e información insuficiente, la regla de abstención que la operacionaliza y el protocolo de validación que separa la observabilidad de la eficacia. Tres conclusiones se desprenden del diseño.

La primera es que la evaluación de riesgo puede desplazarse desde el juicio del comprador hacia el sistema sin requerir la cooperación de la plataforma: las ocho características de la tabla de características se derivan del contenido que el navegador ya recibió, lo que distingue la propuesta de la línea dominante en detección de fraude [5].

La segunda es que la regla de abstención explícita no es un detalle de implementación sino una condición de diseño. Un instrumento que presentara como seguro aquello que solo desconoce trasladaría al comprador un riesgo que no ha evaluado, y penalizaría a comercios legítimos que simplemente no publicitan sus garantías.

La tercera es que intervenir sobre la información del comprador tiene fundamento teórico y no solo utilidad práctica: la cantidad de reseñas falsas en equilibrio decrece con la fracción de consumidores capaces de interpretar correctamente los indicadores de una ficha [4]. El efecto de la herramienta no se agota en quien la instala.

La limitación principal se ha declarado a lo largo del artículo: la arquitectura no ha sido implementada. El único resultado experimental disponible es de naturaleza diagnóstica y apunta contra los propios datos: cinco algoritmos clasifican sin error la partición de prueba, lo que revela que el conjunto es separable por construcción. Las métricas obtenidas sobre él no estiman la calidad de la estimación de riesgo. Lo presentado es un diseño y un protocolo para someterlo a prueba, no un sistema evaluado.

El trabajo futuro tiene un orden obligado. El primero es medir qué características resultan legibles en fichas reales, con especial atención al reparto entre plataformas grandes y vendedores independientes. El segundo es construir un conjunto de datos más sólido, cuyas etiquetas provengan de una fuente independiente del vector de entrada; sin él, cualquier métrica seguirá midiendo la regla que generó esas etiquetas.

Una línea distinta es la detección del comportamiento fraudulento del vendedor, que exige evidencia sobre operaciones consumadas y la colaboración de las plataformas; constituye una recomendación para investigaciones posteriores antes que una extensión del sistema aquí descrito.

REFERENCIAS

- [1] V. Balakrishnan, U. Ahmed, and F. Basheer, "Personal, environmental and behavioral predictors associated with online fraud victimization among adults," *PLoS ONE*, vol. 20, no. 1, p. e0317232, Jan. 2025, doi: 10.1371/journal.pone.0317232.
- [2] J. M. Whittaker, M. Edwards, C. Cross, and M. Button, "I have only checked after the event": Consumer approaches to safe online shopping," *Vict. Offender*, vol. 18, no. 7, pp. 1259–1281, 2023, doi: 10.1080/15564886.2022.2130486.
- [3] K. Zhang, H. Wang, M. Chen, X. Chen, L. Liu, Q. Geng, and Y. Zhou, "Leveraging machine learning to proactively identify phishing campaigns before they strike," *J. Big Data*, vol. 12, Art. no. 124, 2025, doi: 10.1186/s40537-025-01174-x.
- [4] Y. Lei, F. Ødegaard, and H. Pun, "Effect of counterfeits and fake reviews in markets for credence goods," *Omega*, vol. 131, p. 103218, Feb. 2025, doi: 10.1016/j.omega.2024.103218.
- [5] T. Lawanna, "An adaptive CBR-agent AI model for detecting fraudulent user behavior in digital marketplace platforms," *J. Intell. Decis. Making Inf. Sci.*, vol. 3, no. 2, pp. 1210–1236, 2026.
- [6] A. S. Rofrudin, Orvalamarva, and R. R. Saedudin, "Comparative analysis of information security methods in e-commerce environment," *Int. J. Adv. Sci. Eng. Inf. Technol.*, vol. 15, no. 6, pp. 1740–1746, Dec. 2025.
- [7] G. Kostopoulos, A. Stefani, V. Vasiladis, and S. Kotsiantis, "Deep learning for e-commerce: Recent developments in prediction, personalization and decision intelligence," *Appl. Sci.*, vol. 16, Art. no. 2263, Feb. 2026, doi: 10.3390/app16052263.
- [8] Y. Jiang and P. Du, "Cross-border e-commerce credit risk early warning model based on deep learning," *Int. J. Reasoning-based Intell. Syst.*, vol. 17, no. 10, pp. 1–9, Aug. 2025, doi: 10.1504/IJRS.2025.10072955.
- [9] R. Das *et al.*, "Towards the development of an explainable e-commerce fake review index: An attribute analytics approach," *Eur. J. Oper. Res.*, vol. 317, no. 2, pp. 382–400, Sep. 2024, doi: 10.1016/j.ejor.2024.03.008.
- [10] S. A. Rajagukguk and D. Sofyan, "Detecting sophisticated fake reviews on e-commerce platforms using adversarial transformer networks," *Eng. Technol. Appl. Sci. Res.*, vol. 15, no. 6, pp. 29840–29845, Dec. 2025, doi: 10.48084/etasr.13369.
- [11] J. M. Thilini Jayasinghe and S. Dassanayaka, "Detecting deception: Employing deep neural networks for fraudulent review detection on Amazon," *Neural Comput. Appl.*, vol. 37, no. 26, pp. 21715–21742, Sep. 2025, doi: 10.1007/s00521-025-11485-y.
- [12] A. Mutemi and F. Bacao, "E-commerce fraud detection based on machine learning techniques: Systematic literature review," Sep. 2025, doi: 10.26599/BDMA.2023.9020023.
- [13] A. Janavičiūtė, A. Liutkevičius, G. Dabužinskas, and N. Morkevičius, "Experimental evaluation of possible feature combinations for the detection of fraudulent online shops," *Appl. Sci. (Switzerland)*, vol. 14, no. 2, Jan. 2024, doi: 10.3390/app14020919.
- [14] M. Sánchez-Paniagua, E. Fidalgo, E. Alegre, and F. Jáñez-Martino, "Fraud detection in e-commerce: A comparative analysis of features to enhance machine learning models," *Electron. Commerce Res.*, Apr. 2025, doi: 10.1007/s10660-025-10029-9.
- [15] L. Anand, H.-N. Goh, C.-Y. Ting, and A. Quek, "Identifying fraud sellers in e-commerce platform," Mar. 2025, doi: 10.62527/joiv.9.2.3479.
- [16] S. M. Abd-Alhaleem, H. A. Ali, N. F. Soliman, A. D. Algarni, and H. S. Marie, "Advancing e-commerce authenticity: A novel fusion approach based on deep learning and aspect features for detecting false reviews," *IEEE Access*, vol. 12, pp. 116055–116070, 2024, doi: 10.1109/ACCESS.2024.3435916.
- [17] J. D. Duarte *et al.*, "Machine learning for early detection of phishing URLs in parked domains: An approach applied to a financial institution," *IEEE Access*, vol. 13, pp. 145736–145753, 2025, doi: 10.1109/ACCESS.2025.3599454.
- [18] J. Aurazo and F. Gasmi, "Digital payment systems in emerging economies: Lessons from Kenya, India, Brazil, and Peru," *Inf. Econ. Policy*, vol. 69, p. 101113, Dec. 2024, doi: 10.1016/j.infoecopol.2024.101113.
- [19] T. N. Tran, L. D. Nghi, and D. T. K. Chinh, "Perceived risk and trust as moderators between online shopping intention and purchase decisions," *Emerg. Sci. J.*, vol. 10, no. 2, pp. 1101–1116, Apr. 2026, doi: 10.28991/ESJ-2026-010-02-026.
- [20] C. Bianchi and M. A. Saleh, "Investigating the drivers of e-commerce continuance intentions among older consumers in Latin America," *J. Internet Commerce*, vol. 23, no. 4, pp. 384–413, 2024, doi: 10.1080/15332861.2024.2424141.
- [21] P. Landeta-López, J. M. García, C. Guevara-Vega, and A. Ruiz-Cortés, "LLMs applied to web scraping and web crawling: A systematic review," *Computing*, vol. 108, Art. no. 78, May 2026, doi: 10.1007/s00607-026-01666-5.
- [22] J. Brooke, "SUS—A quick and dirty usability scale," in *Usability Evaluation in Industry*, P. W. Jordan, B. Thomas, B. A. Weerdmeester, and I. L. McClelland, Eds. London, U.K.: Taylor & Francis, 1996, pp. 189–194.