

Antes del Click: Análisis de Riesgo del Lado del Cliente para Mitigar Estafas en Compras Digitales

Mathias Alejandro Jave Diaz
Ingeniería de Software
Universidad Peruana de
Ciencias Aplicadas
Lima, Perú
0009-0009-3705-505X

Alex Ramon Alberto Avila Asto
Ingeniería de Software
Universidad Peruana de
Ciencias Aplicadas
Lima, Perú
0009-0008-5624-8482

Fidel Eugenio Garcia Rojas
Ingeniería de Software
Universidad Peruana de
Ciencias Aplicadas
Lima, Perú
0009-0007-4364-0058

Resumen—Los métodos eficaces contra el fraude en el comercio electrónico operan del lado de la plataforma utilizando telemetría interna, dejando al consumidor desprotegido en el momento de decisión. La evidencia indica que la autoconciencia no evita la victimización y que las verificaciones de legitimidad suelen realizarse después de efectuar el pago. Para abordar esta brecha, este artículo propone una arquitectura basada en una extensión de navegador que estima el riesgo de estafa directamente en el equipo del cliente. El sistema evalúa ocho características (como la veracidad del dominio y la autenticidad de reseñas) interpretando el documento HTML ya renderizado, sin enviar peticiones adicionales a la plataforma del vendedor. Se incorpora una regla estricta que distingue el riesgo detectado de la evidencia insuficiente, asegurando que la falta de información en una ficha de producto nunca se presente como seguridad. La evaluación diagnóstica sobre el conjunto de datos disponible reporta que cinco algoritmos de familias distintas clasifican la partición de prueba sin error y con desviación nula. Este resultado demuestra que el conjunto de datos es separable por construcción, lo cual impide estimar el desempeño algorítmico frente a vendedores fraudulentos reales. Como solución metodológica, el estudio define un diseño experimental estructurado para someter la herramienta a pruebas empíricas de eficacia y usabilidad con usuarios.

Index Terms—Comercio electrónico, compras digitales, extensión de navegador, riesgo de estafas, riesgo del lado del cliente

I. INTRODUCCIÓN

La prevención de estafas en compras digitales descansa hoy, en buena medida, sobre la prudencia del comprador. Se le recomienda revisar la reputación del vendedor, desconfiar de precios inverosímiles y comprobar la dirección del sitio antes de pagar. El supuesto implícito es que un comprador informado se protege a sí mismo.

La evidencia no sostiene ese supuesto. Una encuesta a 820 adultos, replicada sobre una segunda muestra de 629, encontró que la autoconciencia sobre privacidad digital no predijo significativamente la victimización, mientras que la sobreconfianza sí la incrementó, con una razón de momios (*odds ratio*) de 1.437 (IC 95 % [1.234, 1.673]); se concluye allí que el conocimiento, por sí solo, no impide que el usuario termine siendo víctima [1]. El complemento conductual es igualmente desfavorable: la verificación del comprador tiende a ocurrir después del evento, cuando el pago ya se realizó [2].

El problema se agrava porque los indicadores que el comprador aprendió a usar han perdido poder discriminante. Numerosas páginas de suplantación emplean hoy certificados válidos de capa de conexión segura (SSL), obtenidos mediante servicios automatizados, de modo que apoyarse únicamente en la verificación SSL resulta insuficiente [3]. Y se ha demostrado formalmente que la reputación visible es manipulable por diseño: en equilibrio, el vendedor auténtico no adquiere reseñas falsas, mientras que el falsificador puede hacerlo para inducir a error [4]. La conexión cifrada y la buena puntuación, las dos heurísticas más difundidas, son precisamente las que un defraudador competente puede exhibir.

Existen métodos eficaces contra el fraude, pero se despliegan en un plano al que el comprador no accede. Los sistemas desplegados por el operador de la plataforma alcanzan desempeños elevados apoyándose en telemetría interna [5], y las contramedidas de seguridad revisadas en la literatura se implementan y financian dentro de la empresa de comercio [6]. Ninguna de ellas alcanza al comprador que evalúa una ficha en una plataforma o ante un vendedor que no las adoptó.

Este trabajo propone desplazar la evaluación desde el juicio del comprador hacia una estimación automática que se ejecute en su propio navegador, sobre la información que él ya tiene delante y antes de que pague. La pregunta que aborda es si un conjunto de características extraíbles del lado del cliente (sin acceso privilegiado a la plataforma y sin recolección automatizada de datos) basta para producir una advertencia útil en el punto de decisión.

El propósito de este sistema se delimita a la estimación probabilística del nivel de riesgo de un vendedor mediante una escala ordinal, no a la emisión de un dictamen categórico de fraude. Esta distinción tiene dos implicancias operativas: primero, admite declaraciones explícitas de insuficiencia de evidencia en lugar de forzar decisiones binarias; segundo, el sistema se evalúa en función de la mitigación de riesgo y las advertencias infundadas, en lugar de utilizar métricas de clasificación estándar contra una verdad de referencia inexistente en la ficha de producto.

Sus contribuciones son tres. La primera es un conjunto de ocho características de riesgo extraíbles desde el cliente, con una regla explícita que distingue el riesgo detectado

de la evidencia insuficiente, de modo que la ausencia de información nunca se presente como seguridad. La segunda es una arquitectura de tres capas cuyo artefacto principal es una aplicación nativa en el navegador, es decir una extensión, acompañada de un cliente multiplataforma complementario; sobre ella operan un motor de riesgo, que reúne el análisis de dominio y la inferencia sobre vendedor y reseñas, y una capa de persistencia que hace trazable cada consulta, todo ello sin consultar a la plataforma del vendedor. La tercera es un protocolo de validación en dos fases que separa la observabilidad de las características de la eficacia del veredicto, junto con las amenazas a la validez que condicionan sus conclusiones.

Debe precisarse desde el inicio que la arquitectura aquí descrita es una propuesta de diseño y no ha sido implementada, por lo que este trabajo no aporta resultados experimentales sobre ella.

El resto del artículo se organiza de la siguiente manera. La Sección II revisa el trabajo relacionado; la Sección III explica conceptos preliminares relacionados al contexto de la investigación; la Sección IV detalla la arquitectura propuesta; la Sección V describe los experimentos preliminares; la Sección VI presenta las conclusiones y el trabajo futuro.

II. TRABAJO RELACIONADO

La estimación de riesgo en comercio electrónico constituye hoy un campo consolidado. Esta sección lo recorre en cinco apartados: el papel que la inteligencia artificial ha adquirido en la estimación de riesgo, la detección de vendedores fraudulentos desde la plataforma, la identificación de reseñas manipuladas, la detección de sitios de suplantación y las contramedidas desplegadas por el comercio; un sexto recoge la brecha que este trabajo aborda. Su revisión muestra un patrón común: los avances se producen en el lado de quien opera la plataforma o el servicio, y rara vez alcanzan al comprador en el momento en que decide.

1. *Inteligencia artificial aplicada a la estimación de riesgo*

El aprendizaje profundo se ha consolidado como la tecnología sobre la que las plataformas de comercio electrónico resuelven predicción, personalización y decisión, incluida la gestión de la confianza, la integridad de las reseñas y la detección de fraude [7]. El desplazamiento tuvo una causa concreta: los mecanismos de seguridad basados en reglas no escalan ante el volumen, la heterogeneidad y el carácter adaptativo de las amenazas actuales, por lo que el aprendizaje profundo pasó a operar como tecnología habilitante para la detección de amenazas, el modelado de riesgo conductual y la supervisión a gran escala [7]. El mismo trabajo señala que el contenido generado por usuarios (reseñas, calificaciones e imágenes) resulta decisivo en la decisión de compra y, a la vez, altamente vulnerable a la manipulación y al fraude coordinado, lo que sitúa la autenticidad de las reseñas en el centro del problema.

Un ejemplo cuantificado ilustra el nivel alcanzado y, a la vez, su condición de posibilidad. Un modelo híbrido de red convolucional con máquina de aprendizaje extremo optimizada

alcanza una exactitud de 96.23 % y un AUC de 0.9118 al clasificar el riesgo crediticio de empresas de comercio transfronterizo [8]. El objeto estimado no es el riesgo de estafa que percibe un comprador individual, y el insumo que ese desempeño requiere (información financiera de la contraparte, condiciones de operación y evaluaciones de la plataforma) no es accesible desde el navegador de quien está por comprar [8].

Los algoritmos que sostienen esta línea son identificables. En la detección de reseñas manipuladas predominan los modelos de lenguaje basados en transformadores: variantes de BERT ajustadas al dominio del comercio electrónico [9], arquitecturas adversariales sobre la misma familia [10] y redes neuronales profundas aplicadas a reseñas de plataformas concretas [11], en ocasiones combinadas con memorias de largo y corto plazo bidireccionales y con herramientas de explicabilidad para justificar el veredicto [9]. En la estimación de riesgo del vendedor y en la detección de sitios de suplantación predominan, en cambio, los métodos de ensamble y los clasificadores de margen: bosques aleatorios, máquinas de soporte vectorial, árboles de decisión y gradiente potenciado aparecen de forma recurrente [12]–[14], y el marco de detección más reciente combina cuatro de ellos con selección de características mediante SHAP y eliminación recursiva [3]. Esta división no es casual: el texto libre de las reseñas exige representaciones contextuales, mientras que los atributos estructurales de una ficha, heterogéneos y de baja dimensionalidad, se ajustan mejor a los métodos por árboles.

Estos enfoques se sitúan invariablemente en la plataforma, en la institución financiera o en el operador del servicio, que son quienes disponen de los registros y ejecutan los modelos. Y aun ahí admiten fallos: los detectores más avanzados pueden ser eludidos mediante perturbaciones adversariales u ofuscación lingüística [7], de modo que la defensa centralizada, por sólida que sea, deja pasar casos que alcanzan al comprador sin que este disponga de instrumento alguno.

2. *Detección de fraude desde la plataforma*

La detección de fraude en comercio electrónico ha alcanzado madurez metodológica: una revisión sistemática reciente [12] recoge la diversidad de técnicas aplicadas al problema, y trabajos posteriores han refinado la selección de características [13], [14] y la identificación de vendedores fraudulentos dentro de una plataforma [15]. El exponente más reciente ilustra a la vez el alcance y el límite de la línea: combinando razonamiento basado en casos con un sistema multiagente se alcanza un área bajo la curva (AUC) de 0.979 sobre unos 1.27 millones de instancias, resistiendo la deriva del comportamiento fraudulento mejor que los clasificadores convencionales [5]. Ese desempeño se sostiene sobre datos que solo el operador posee (registros transaccionales, huellas de dispositivo y un grafo de interacción de más de un millón de aristas), a los que el comprador que evalúa una ficha no tiene acceso.

3. *Reseñas manipuladas*

La segunda línea aborda la autenticidad de las reseñas y, a los detectores ya mencionados, suma enfoques de fusión con

características de aspecto [16]. A esa discusión se agrega un resultado de naturaleza distinta [4]. Mediante un modelo de competencia entre un vendedor auténtico y un falsificador que comparten ficha de producto, se muestra que en equilibrio el vendedor auténtico no adquiere reseñas falsas mientras que el falsificador puede hacerlo para inducir a error al comprador. La manipulación de la reputación no es, por tanto, una anomalía del mercado sino un comportamiento previsible de quien tiene algo que ocultar. El mismo trabajo establece que la cantidad de reseñas falsas en equilibrio decrece con la fracción de consumidores capaces de interpretar correctamente los indicadores de la ficha, lo que sitúa la información del comprador (y no solo la capacidad de detección de la plataforma) como palanca de mitigación.

4. Suplantación de sitios y análisis de dominio

La tercera línea proviene de la seguridad informática. En [17] se detectan localizadores uniformes de recursos (URL) de *phishing* en dominios aparcados a partir de características derivadas del registro, aplicándolo a una institución financiera, y en [3] se propone un marco de detección sobre 1353 URL con selección de características por explicaciones aditivas de Shapley (SHAP) y eliminación recursiva, con una exactitud de 0.984.

Lo más relevante de este último para el presente trabajo no es el desempeño del clasificador sino el diagnóstico que lo motiva: el certificado SSL válido dejó de discriminar, porque los atacantes lo obtienen mediante servicios automatizados, y las listas de bloqueo del navegador no alcanzan a cubrir dominios desplegados y retirados en horas [3].

5. Contramedidas del lado del comercio

Una revisión sistemática de métodos de seguridad en entornos de comercio electrónico [6] inventaría siete familias de controles (cifrado SSL/TLS, cortafuegos, sistemas de detección de intrusiones, actualizaciones, capacitación del personal, inteligencia artificial y colaboración con terceros) y concluye que ninguna basta por sí sola, por lo que la defensa debe articularse en capas. Las siete, no obstante, se implementan y se financian dentro de la empresa de comercio. Ninguna protege al comprador que interactúa con una plataforma o un vendedor que no las adoptó.

6. Brecha de investigación

El comprador ocupa así una posición singular: existen métodos eficaces contra los vendedores fraudulentos, contra las reseñas manipuladas y contra la suplantación de sitios, pero todos requieren datos, infraestructura o autoridad de los que él carece, y las recomendaciones dirigidas a él son educativas y de eficacia limitada [1], [2]. Ninguno de los trabajos revisados combina características de dominio, de vendedor y de reseñas en un instrumento que se ejecute del lado del comprador y emita su advertencia antes del pago. Esa es la brecha que este trabajo aborda, con la salvedad de que lo presentado es una propuesta de arquitectura y no un sistema evaluado.

III. CONTEXTO

Esta sección delimita el marco conceptual y técnico que sustenta la arquitectura desarrollada. Para ello, se fundamenta el entorno económico de aplicación, se define la naturaleza de los atributos extraíbles, se contrasta el método de lectura frente a las técnicas de recolección automatizada, y se establecen las reglas de interpretación para el manejo de evidencia insuficiente.

1. Comercio digital y confianza en el Perú

El comercio electrónico peruano opera en un entorno donde la adopción del pago digital no está acompañada por un nivel equivalente de confianza del consumidor. Un análisis comparado de sistemas de pago en economías emergentes reporta que la falta de confianza en las instituciones es una barrera clave, provocando que solo el 57 % de los adultos utilice pagos digitales, frente al 64 % global [18]. Esta desconfianza genera un impacto directo en el mercado legítimo, ya que la intención y continuidad de compra en canales digitales dependen fuertemente del riesgo percibido por el usuario [19] [20]. Por lo tanto, la incapacidad de verificar a un vendedor desconocido antes del pago no solo afecta a las víctimas de fraude, sino que impone una fricción comercial sobre los vendedores honestos.

2. Características extraíbles del lado del cliente

Para efectos de esta arquitectura, se define como *característica extraíble del lado del cliente* a todo atributo de una publicación que cumpla tres condiciones simultáneas: es visible para el comprador antes del pago, reside en el documento ya entregado al navegador, y no requiere acceso a interfaces internas de la plataforma. Atributos como la puntuación del producto, el número de reseñas y el nombre de dominio cumplen estrictamente con estos criterios.

Esta distinción separa el presente trabajo de la línea dominante en detección de fraude, la cual se apoya en telemetría interna (registros de transacciones, huellas de dispositivo, grafos de interacción) completamente inaccesible para el comprador [5]. Por su parte, el comprador dispone de un conjunto de características restringido, por lo que la pregunta central que este trabajo aborda es si dichos datos accedibles bastan para producir una advertencia útil.

3. Lectura del DOM y recolección automatizada

La operación que realiza la extensión requiere una caracterización precisa, con consecuencias técnicas y no solo terminológicas. Una revisión sistemática de noventa y un estudios define el *web scraping* y el *web crawling* como el proceso automatizado de extracción de datos en el que las herramientas de rastreo navegan a través de múltiples páginas [21]. La extensión propuesta no realiza ninguna de las dos operaciones: no navega, porque es el usuario quien decide qué ficha abrir; no recorre múltiples páginas, porque opera sobre el documento que el navegador ya renderizó; y no emite peticiones adicionales hacia la plataforma. Su

operación consiste en interpretar, en beneficio de quien la ejecuta, contenido que ya le había sido entregado.

Esta caracterización acota también las limitaciones del enfoque. La misma revisión advierte que las herramientas apoyadas en selectores predefinidos son susceptibles a cambios de maquetación, y que entre los desafíos del área figuran los riesgos legales [21]. La primera observación se declara como amenaza a la validez en la Sección V-C; la segunda es la razón para no retransmitir contenido de la plataforma más allá de las características que el veredicto requiere.

4. Protección de pago declarada

Las plataformas de comercio de mayor tamaño publican esquemas mediante los cuales retienen el pago hasta la conformidad del comprador o garantizan su devolución ante incumplimiento. Esa declaración es un compromiso público y verificable en la propia ficha, y constituye por ello una característica legítima.

Su ausencia, en cambio, no es informativa en el mismo sentido: un vendedor independiente puede ofrecer condiciones equivalentes sin anunciarlas, o anunciarlas donde la extensión no alcanza a leer. Tratar el silencio como evidencia de inseguridad convertiría una limitación del observador en una acusación sobre el observado, tanto más cuanto que las contramedidas disponibles se despliegan y se financian del lado del comercio [6] y su ausencia visible correlaciona con el tamaño del vendedor antes que con su honestidad.

IV. MÉTODO

Esta sección describe la arquitectura propuesta. La unidad de análisis es una *ficha de producto* que el comprador tiene abierta en su navegador: el sistema no recorre catálogos ni consulta interfaces privilegiadas de la plataforma, sino que opera sobre la misma información que el comprador ya tiene delante. Esa restricción gobierna todas las decisiones de diseño que siguen y separa esta propuesta de los sistemas de detección desplegados por el operador del comercio [5].

La arquitectura se organiza en tres capas (cliente, motor de riesgo y persistencia) y se detalla en la Fig. 1.

1. Capa cliente: observación sin recolección automatizada

La capa cliente se implementa como una *aplicación nativa en el navegador* (una extensión) que se activa cuando el usuario abre una ficha de producto en una plataforma soportada. La extensión recorre el árbol DOM ya renderizado, localiza mediante selectores los elementos que exponen los atributos de interés (precio, puntuación, número de reseñas, identidad del vendedor, medios de pago anunciados, políticas de garantía) y construye un vector de observaciones que envía al motor de riesgo. La extensión constituye el artefacto principal de esta propuesta, y no por conveniencia de implementación. Es el único punto del sistema que coincide, en espacio y en tiempo, con el instante en que el comprador decide: se ejecuta sobre la ficha que él tiene abierta, sin mediación de la plataforma y antes de que el pago ocurra. Ningún otro componente de esta

arquitectura, ni las aproximaciones revisadas en la Sección II, coincide de ese modo con el instante de la decisión.

Un cliente complementario consume el mismo servicio y cubre la compra que ocurre fuera del navegador de escritorio. Su papel es de cobertura, no de sustitución: opera sobre lo que el usuario le proporciona o la plataforma expone públicamente, sin acceso al documento renderizado, de modo que resolverá previsiblemente menos características. Su forma concreta, web o móvil, no la determina la arquitectura, que solo exige consumir la misma interfaz y respetar la misma regla de abstención.

Esta capa existe porque, según la evidencia recogida en la Sección I, la advertencia que ha de llegar antes del pago debe producirla el sistema y no el juicio del comprador [1], [2]. La ventaja técnica de resolverlo en el cliente es que la información necesaria ya fue entregada al navegador: no hay navegación automatizada ni recorrido de múltiples páginas, que es lo que define al *web scraping* [21], y el sistema no emite hacia la plataforma del vendedor ninguna petición que el comprador no hubiera cursado en cualquier caso.

«Del lado del cliente» no significa, sin embargo, «sin servidor»: el vector observado viaja al motor de riesgo, el analizador de dominio consulta servicios de registro y de resolución de nombres, y cada consulta queda registrada. La propuesta elimina la dependencia respecto de la plataforma del vendedor a costa de introducir un nuevo tercero de confianza, con la política de retención y anonimización que ello exige. Su otra contrapartida, declarada en la Sección V-C, es la fragilidad ante cambios de maquetación, pues los selectores predefinidos son sensibles a modificaciones estructurales del sitio [21].

La Fig. 2 traza el orden temporal de una consulta y precisa lo que la vista estática no expresa: entre la apertura de la ficha y la advertencia no se emite ninguna petición hacia la plataforma del vendedor.

2. Conjunto de características y regla de abstención ante evidencia ausente

El motor de riesgo trabaja sobre ocho características, resumidas en la Tabla I. Cada característica se define junto con la capa que la computa, su dominio de valores y (de manera central para esta propuesta) el valor que toma cuando no puede determinarse.

La *protección de pago declarada* fija el criterio que rige al resto. Plataformas como MercadoLibre, Amazon o AliExpress declaran en la ficha que retienen el pago o que garantizan la devolución ante incumplimiento, y la extensión detecta esa declaración; cuando no la encuentra, el sistema no infiere que el pago sea inseguro sino que registra la característica como *no verificable*, según la distinción establecida en la Sección III-D.

Esta regla se aplica de manera uniforme: para toda característica se distingue entre valor conocido, valor ausente por no aplicar y valor indeterminado por falta de evidencia. Una característica se considera *resuelta* cuando toma un valor conocido; los otros dos estados la dejan sin resolver, y la Tabla I indica cuál de ellos adopta cada característica cuando la ficha no aporta evidencia. El agregador propaga esa distinción hasta




Fig. 1. Arquitectura lógica propuesta. La extensión lee el DOM ya renderizado de una página abierta por el propio usuario; el motor de riesgo enriquece esas observaciones con análisis de dominio e inferencia sobre vendedor y reseñas, y el agregador emite el veredicto con su nivel de confianza.

TABLA I
CONJUNTO DE CARACTERÍSTICAS, ORIGEN Y COMPORTAMIENTO ANTE EVIDENCIA AUSENTE

Característica	Se computa en	Valores	Si no hay evidencia
Protección de pago declarada	Cliente	declarada / no declarada	<i>no verificable</i>
Veracidad de dominio	Backend	escala ordinal	<i>no verificable</i>
Reputación vendedor	Backend	escala ordinal	<i>no verificable</i>
Autenticidad de reseñas	Backend	proporción estimada	<i>no verificable</i>
Puntuación producto	Cliente	continua	ausente
Presencia de reseñas	Cliente	binaria	ausente
Políticas de garantía	Cliente	ordinal	<i>no verificable</i>
Volumen de ventas	Cliente	entero	ausente

el veredicto mediante dos condiciones que deben cumplirse conjuntamente.

La primera es de cobertura. Sea r el número de características resueltas de las ocho; el sistema exige $r \geq 4$. La segunda es de suficiencia por dimensión. Las ocho características cubren tres dimensiones de riesgo distintas: la identidad del sitio (veracidad de dominio), la fiabilidad del vendedor (reputación, volumen de ventas, políticas de garantía y protección de pago declarada) y la evidencia de la comunidad (puntuación, presencia y autenticidad de reseñas). El sistema exige que al

menos una característica de cada dimensión se haya resuelto.

Cuando ambas condiciones se satisfacen, el veredicto se emite con un nivel de confianza derivado de la cobertura: alta si $r \geq 6$, media en caso contrario. Cuando alguna falla, el sistema no emite riesgo sino *evidencia insuficiente*, junto con la lista de características que no pudo resolver.

La segunda condición distingue esta regla de un simple conteo: un umbral global trataría por igual la pérdida de tres características redundantes y la de la única que informa sobre la identidad del sitio, que deja al comprador sin protección frente a la suplantación. La justificación de fondo es la asimetría de costos, pues presentar como seguro aquello que solo es desconocido traslada al comprador un riesgo que el sistema no ha evaluado.

3. Descomposición en servicios

El motor de riesgo de la Fig. 1 no es un bloque único: se despliega en servicios desacoplados. Un servicio central expone la interfaz que consumen los clientes y delega la estimación de riesgo del vendedor y el procesamiento de reseñas en servicios independientes, cada uno con su propio ciclo de despliegue; la persistencia se resuelve sobre una base relacional y la identidad mediante un proveedor externo, que permite asociar cada consulta a su origen sin custodiar credenciales propias, si bien el uso de la extensión no exige que el comprador disponga de cuenta. La separación responde a una propiedad que el sistema necesita: el clasificador de riesgo se reentrena cuando cambia el conjunto de características disponibles y el detector de reseñas cuando cambian los patrones lingüísticos del fraude, de modo que aislarlos permite sustituir cualquiera




Fig. 2. Secuencia de una consulta, desde la apertura de la ficha hasta la advertencia. Las barras verticales indican los intervalos de actividad de cada componente; las flechas discontinuas, los retornos. Ninguna flecha sale hacia la plataforma del vendedor: las únicas comunicaciones salientes van de la extensión a los componentes del motor de riesgo, y las consultas del analizador a los servicios de registro y de resolución de nombres se resumen en su intervalo de actividad. El agregador aplica la regla de abstención antes de emitir el veredicto.

de los dos sin interrumpir el servicio ni versionar la interfaz que consume la extensión.

4. Analizador de veracidad de dominio

El analizador de dominio recibe el nombre de host de la ficha y devuelve una estimación ordinal de veracidad. Su entrada se compone de atributos del registro del dominio, de la cadena de resolución (incluidos los registros de nombre canónico (CNAME) y el espacio de nombres al que delega) y de la coincidencia con patrones morfológicos asociados a campañas de suplantación.

Este módulo es necesario porque, como se expuso en la Sección II-D, ni el certificado SSL ni las listas de bloqueo del navegador discriminan ya la suplantación [3]. La ventaja de analizar registro y resolución en lugar de contenido es que estos atributos son costosos de falsificar y están disponibles antes de que el usuario interactúe con la página. Se ha mostrado que características derivadas del registro permiten detectar URL de *phishing* en dominios aparcados en una institución financiera [17], lo que sostiene la viabilidad del enfoque sobre esta clase de atributos. El módulo no reemplaza la comprobación de certificado, que la literatura de seguridad en comercio electrónico caracteriza como el control fundacional y de menor costo [6], sino que la complementa en la dimensión donde aquella dejó de ser informativa.

5. Modelos de inferencia sobre vendedor y reseñas

Dos componentes de aprendizaje automático completan el motor. El primero estima el riesgo del vendedor a partir del vector de características extraídas y devuelve un nivel ordinal; el segundo estima la proporción de reseñas presumiblemente

TABLA II
CONFIGURACIÓN DEL CLASIFICADOR DE RIESGO DEL VENDEDOR

Parámetro	Valor
Algoritmo	Bosque aleatorio
Número de árboles	100
Variables de entrada	7
Clases	Riesgo alto / moderado / bajo
Registros	10 000
Distribución de clases	3 333 / 3 334 / 3 333
Partición entrenamiento–prueba	80 / 20
Semilla	42

fraudulentas en la ficha. Sus configuraciones se resumen en las Tablas II y III.

Para la estimación de riesgo del vendedor se emplea un bosque aleatorio y no una arquitectura de mayor capacidad, por tres propiedades que el problema exige. La dimensionalidad: el vector de entrada contiene ocho características heterogéneas (binarias, categóricas, discretas y continuas), un régimen en el que los métodos de ensamble por árboles operan sin normalización ni codificaciones adicionales. La interpretabilidad: el modelo expone la contribución relativa de cada característica, con la que se construye la explicación que acompaña al veredicto. Y el costo: la inferencia sobre cien árboles es despreciable frente a la latencia de red de la consulta.

El clasificador del que se dispone actualmente difiere de esta especificación: fue entrenado sobre siete entradas, sin la veracidad de dominio que este trabajo incorpora. Añadirle exige reentrenar el modelo sobre un conjunto que la contenga,

TABLA III
CONFIGURACIÓN DEL CLASIFICADOR DE RESEÑAS FRAUDULENTAS

Arquitectura		Ajuste fino	
Modelo base	DistilBERT	Optimizador	AdamW <i>fused</i>
Cabezal	Clasif. de secuencias	Tasa de aprendizaje	2×10^{-5}
Capas del codificador	6	Planificador	Lineal, sin calentamiento
Cabezas de atención	12	Decaimiento de pesos	0.01
Dimensión de representación	768	$\beta_1, \beta_2, \epsilon$	0.9, 0.999, 10^{-8}
Dimensión <i>feed-forward</i>	3072	Recorte de gradiente	1.0
Parámetros	66.96 M (FP32)	Tamaño de lote (entr./eval.)	16 / 16
Activación	GELU	Acumulación de gradiente	1
<i>Dropout</i> gen./aten./clasif.	0.1 / 0.1 / 0.2	Épocas	1
Longitud máx. de secuencia	512 <i>tokens</i>	Precisión numérica	FP32
Tamaño de vocabulario	30 522	Evaluación	Por época
Clases	REAL, FAKE	Semilla	42

y su ausencia es consecuencia de que este trabajo describe la arquitectura propuesta y no una implementación ya construida.

El segundo componente estima la autenticidad de las reseñas con DistilBERT, un codificador transformador destilado cuya configuración de ajuste recoge la Tabla III. La elección de una variante destilada responde a una restricción operativa: la inferencia ocurre entre la consulta de la extensión y la emisión del veredicto, de modo que su costo incide sobre el tiempo que el comprador espera. Seis capas y 66.96 millones de parámetros reducen ese costo frente a un codificador completo, y la ejecución en precisión de 32 bits sobre unidad central de proceso evita exigir aceleración por hardware. La contrapartida es una capacidad de representación menor, cuya repercusión sobre la exactitud debe cuantificarse en la validación.

El ajuste fino se realizó durante una época con tasa de aprendizaje de 2×10^{-5} y planificador lineal, valores habituales para adaptar un codificador preentrenado sin alterar las representaciones aprendidas. La entrada del clasificador no es únicamente el texto de la reseña: se serializan conjuntamente la categoría del producto, la calificación asignada y el texto, de modo que el modelo dispone del contexto en el que la reseña fue emitida. Esta decisión responde a que una misma formulación puede resultar verosímil o anómala según la calificación que la acompaña. La brevedad del ajuste, una sola época, constituye una limitación que la Sección V recoge. Debe señalarse además que este trabajo no evalúa el clasificador de reseñas: la Tabla III documenta su configuración para hacer reproducible el componente, no para respaldar afirmación alguna sobre su desempeño. Ni el corpus de ajuste ni sus métricas de prueba forman parte de lo reportado aquí, y su evaluación queda comprendida en el trabajo futuro de la Sección VI.

La inferencia sobre reseñas es necesaria porque, según el resultado de equilibrio citado en la Sección II-C, la reputación visible es manipulable por construcción [4]: tomar la puntuación agregada como indicador de confianza coincide con el comportamiento que el vendedor fraudulento busca inducir. La arquitectura incorpora por ello la estimación de autenticidad de las reseñas como característica independiente de la puntuación, si bien la forma en que ambas deben combinarse, y en

particular si la segunda debe corregir a la primera antes de la clasificación, constituye una decisión de diseño abierta que la validación deberá resolver.

6. Agregación, presentación y persistencia

El agregador combina las características resueltas en un veredicto con cuatro desenlaces posibles: riesgo alto, moderado o bajo cuando la evidencia disponible permite decidir, y *evidencia insuficiente* cuando no. Los tres primeros se acompañan del nivel de confianza y de la lista de características que los sustentan; el cuarto, de las características que no pudieron resolverse. La presentación es deliberadamente explicativa: junto al veredicto se muestra qué características se verificaron, cuáles quedaron indeterminadas y qué acredita cada una, conforme al requisito de trazabilidad que la literatura de detección de fraude ha ido incorporando frente a los clasificadores opacos [5].

Finalmente, cada consulta se registra en una base de datos junto con las características extraídas y el veredicto emitido. El registro cumple dos funciones: habilita la trazabilidad de cada advertencia mostrada al usuario y constituye el conjunto de datos con el que los modelos se reentrenarán en iteraciones posteriores. Dado que la información asociada a una consulta puede revelar hábitos de compra, la política de retención y el nivel de anonimización forman parte del diseño; la Sección V-B fija los términos en que ambos rigen durante la validación.

V. EXPERIMENTOS

Esta sección presenta un resultado diagnóstico sobre el conjunto de datos del que se dispone y describe el diseño con el que se someterá a prueba la arquitectura completa. El primero es un experimento ejecutado; el segundo, un procedimiento previsto. Los umbrales de éxito de cada métrica no se fijan aquí: dependen de la cobertura de características que arroje la primera fase, y establecerlos antes de conocerla sería arbitrario.

1. Separabilidad del conjunto disponible

Antes de evaluar la arquitectura conviene establecer qué puede concluirse del conjunto disponible. Se trata de un conjunto **sintético** de 10 000 registros con tres clases equilibradas,

TABLA IV
DESEMPEÑO DE CINCO ALGORITMOS SOBRE EL CONJUNTO DISPONIBLE

Algoritmo	Exactitud	F1 macro	CV (5)
Bosque aleatorio	1.0000	1.0000	1.0000 $\pm$ 0.0000
XGBoost	1.0000	1.0000	1.0000 $\pm$ 0.0000
Árbol de decisión	1.0000	1.0000	1.0000 $\pm$ 0.0000
SVM (RBF)	1.0000	1.0000	1.0000 $\pm$ 0.0000
k -NN ($k = 5$)	1.0000	1.0000	1.0000 $\pm$ 0.0000

construido ante la ausencia de un conjunto etiquetado público de fichas de vendedores peruanos: sus variables y rangos se derivaron de los factores de riesgo identificados en la Sección II, y las etiquetas se asignaron mediante reglas deterministas sobre esas mismas variables. Declarar esta procedencia es indispensable para interpretar lo que sigue. Sus siete entradas corresponden a siete de las ocho de la Tabla I: la veracidad de dominio, que este trabajo introduce, es la única que no forma parte de ese vector. Se entrenaron cinco algoritmos de familias distintas sobre la misma partición 80/20 con semilla fija, y se validaron además mediante validación cruzada estratificada de cinco pliegues sobre el conjunto completo. La Tabla IV recoge los resultados.

Los experimentos se ejecutaron en un entorno estandarizado para garantizar su reproducibilidad. A nivel de software se utilizó Ubuntu 24.04.3 LTS (kernel 6.8.0-137-generic) con Python 3.11 y las bibliotecas scikit-learn, NumPy y pandas. El hardware consistió en un servidor Supermicro equipado con un procesador Intel Xeon E3-1240 v5 de cuatro núcleos y ocho hilos a 3.90 GHz, con los procesos ejecutados íntegramente en CPU y sin aceleración gráfica dedicada. Las máquinas de soporte vectorial y el clasificador de vecinos más cercanos se encadenaron a un normalizador de media cero y varianza unitaria, por ser los únicos algoritmos del conjunto sensibles a la escala de las características. Los demás hiperparámetros se mantuvieron en sus valores por defecto, con semilla fija en todos los casos: el objetivo no era optimizar el desempeño sino comprobar si existía diferencia alguna entre familias de algoritmos.

Los cinco algoritmos clasifican correctamente los 2000 registros del conjunto de prueba, con desviación nula entre pliegues. El resultado no debe leerse como evidencia de la calidad de ninguno de ellos. Que un clasificador de vecinos más cercanos iguale a un ensamble de gradiente potenciado, y que ambos igualen a un árbol individual, indica que la frontera de decisión es recuperable por cualquier método: el problema es separable por construcción.

Un segundo análisis lo confirma. Un árbol de decisión de profundidad cinco reproduce la regla de etiquetado en su totalidad, y la importancia de las características se concentra en dos (la puntuación del producto, con 0.51, y el volumen de ventas, con 0.46), mientras que tres de las siete no contribuyen en absoluto. Entre estas últimas figura la proporción estimada de reseñas fraudulentas, que es precisamente una de las características sobre las que descansa el argumento de la

Sección IV-E.

De ello se siguen dos consecuencias. La primera es que este conjunto **no permite discriminar entre algoritmos**: la elección del bosque aleatorio descrita en la Sección IV-E se sostiene en sus propiedades de interpretabilidad y costo, no en una comparación empírica que estos datos no pueden arbitrar. La segunda, más relevante, es que las métricas obtenidas sobre él no estiman la calidad del nivel de riesgo asignado, sino la fidelidad con que un modelo recupera la regla que generó sus propias etiquetas. La construcción de un conjunto con etiquetas de origen independiente del vector de entrada es, por tanto, condición previa a cualquier afirmación sobre eficacia.

2. Diseño experimental de la validación

La validación se ejecutará en el Perú, sobre las plataformas y los hábitos descritos en la Sección III-A. Esa elección delimita el alcance de las conclusiones empíricas, no el de la arquitectura: las características de la Tabla I se derivan de elementos presentes en cualquier ficha de producto y no de particularidades del mercado peruano. La propuesta es trasladable a otros contextos, con la salvedad de que la cobertura efectiva de cada característica debe volver a medirse en cada mercado.

La validación se organiza en dos fases con objetivos separables.

Fase 1: observabilidad de las características. Antes de evaluar la utilidad del veredicto es necesario establecer qué fracción de las características de la Tabla I resulta efectivamente legible en fichas reales. Sobre una muestra de fichas de producto de las plataformas de mayor uso en el Perú se registrará, para cada característica, si pudo resolverse o si quedó indeterminada, distinguiendo entre plataformas grandes y vendedores independientes. El desenlace relevante no es un porcentaje agregado sino su distribución: una arquitectura que solo resolviera características en las plataformas que ya ofrecen garantías carecería de utilidad precisamente en el segmento donde el riesgo se concentra.

Fase 2: eficacia con usuarios. Un diseño con dos grupos, con y sin la extensión activa, enfrentará a los participantes a un conjunto de fichas preparadas que incluya casos legítimos y casos con indicadores de fraude. La población objetivo son compradores digitales peruanos de entre 18 y 60 años, con una muestra prevista de cincuenta participantes que otorgarán su consentimiento de forma voluntaria antes de comenzar. Las sesiones se conducirán de manera presencial o en línea, según la disponibilidad de cada participante. Los registros de consulta descritos en la Sección IV-F se recogerán disociados del participante que los originó, se conservarán únicamente durante el periodo de análisis y se eliminarán al cierre del estudio; ningún dato que permita reconstruir el historial de compra de una persona identificada forma parte de lo que el protocolo almacena.

Del comportamiento observado durante la sesión se medirá la tasa de identificación correcta, la tasa de falsos positivos sobre comercios legítimos y el tiempo hasta la decisión. La percepción del participante se recoge mediante un cuestionario

TABLA V
DIMENSIONES DEL INSTRUMENTO DE VALIDACIÓN CON USUARIOS

Dimensión	Qué establece
Usabilidad	Si el veredicto y su explicación se interpretan sin instrucción previa (bloque SUS)
Confianza percibida	Si el participante considera fundada la advertencia que recibe
Riesgo percibido	Si su estimación del riesgo de la ficha varía al disponer de la herramienta
Intención de uso y recomendación	Si declararía seguir usándola fuera del entorno de prueba
Influencia en la decisión	Si la advertencia modificó lo que habría hecho sin ella

estructurado de quince ítems con respuesta en escala de Likert de cinco puntos, organizado en las cinco dimensiones de la Tabla V; el bloque de usabilidad sigue la Escala de Usabilidad del Sistema y se informa sobre su escala de 0 a 100 [22]. Declarar la composición del instrumento permite situar cada conclusión en la dimensión que efectivamente la sostiene: la eficacia se juzga por las tres primeras medidas de comportamiento, y la aceptación, por las dos últimas dimensiones del cuestionario.

La tasa de falsos positivos es la métrica que gobierna el diseño. Un instrumento que advierte con excesiva frecuencia pierde credibilidad y deja de ser consultado, y su costo recae además sobre comercios honestos que no publicitan garantías. Por ello la regla de abstención de la Sección IV distingue el veredicto de riesgo del de evidencia insuficiente: son errores distintos y deben medirse por separado.

3. Amenazas a la validez

Cuatro limitaciones condicionan lo que este diseño podrá concluir, y conviene explicitarlas antes de su ejecución.

La primera afecta a la capa cliente. La extracción depende de selectores sobre el DOM, y se ha advertido que las técnicas apoyadas en selectores predefinidos son sensibles a cambios de maquetación [21]. Una plataforma que rediseñe su ficha reducirá la cobertura de características sin previo aviso, por lo que la Fase 1 debe repetirse periódicamente y no tratarse como una medición única.

La segunda afecta al clasificador de riesgo. Sus etiquetas de entrenamiento se derivan mediante reglas deterministas aplicadas a las mismas características que el modelo recibe como entrada, de modo que el desempeño medido sobre ese conjunto refleja la recuperación de esa regla y no el comportamiento frente a vendedores fraudulentos reales. Su evaluación exige, por tanto, un conjunto de datos con etiquetas de origen independiente del vector de características.

La tercera es de validez ecológica. Un experimento con fichas preparadas mide la capacidad de detección en condiciones de atención deliberada, mientras que la evidencia disponible sugiere que la victimización ocurre justamente cuando esa atención falla [1]. El diseño puede establecer si la herramienta ayuda a quien la mira, no si protege a quien compra distraído.

La cuarta es la más general: la arquitectura supone que el atacante no adapta su comportamiento a las características ob-

servadas, suposición insostenible a mediano plazo porque los defraudadores ajustan sus estrategias frente a los mecanismos de detección [5]. El registro de consultas de la Sección IV-F existe, entre otras razones, para hacer observable esa deriva.

VI. CONCLUSIONES Y TRABAJO FUTURO

Este trabajo ha presentado el diseño de un sistema que estima el riesgo de estafa en el punto de decisión de compra, a partir de características que el comprador ya tiene delante y sin acceso privilegiado a la plataforma. Tres conclusiones se desprenden del diseño.

La primera es que la evaluación de riesgo puede desplazarse desde el juicio del comprador hacia el sistema sin requerir la cooperación de la plataforma: las ocho características de la Tabla I se derivan del contenido que el navegador ya recibió, lo que distingue la propuesta de la línea dominante en detección de fraude, que alcanza desempeños elevados pero requiere telemetría interna [5].

La segunda es que la regla de abstención explícita no es un detalle de implementación sino una condición de diseño. Un instrumento que presentara como seguro aquello que solo desconoce trasladaría al comprador un riesgo que no ha evaluado, y penalizaría a comercios legítimos que simplemente no publicitan sus garantías.

La tercera es que intervenir sobre la información del comprador tiene fundamento teórico y no solo utilidad práctica: la cantidad de reseñas falsas en equilibrio decrece con la fracción de consumidores capaces de interpretar correctamente los indicadores de una ficha [4], de modo que el efecto de la herramienta no se agota en quien la instala.

La limitación principal ha sido declarada a lo largo del artículo: la arquitectura no ha sido implementada. El único resultado experimental disponible es de naturaleza diagnóstica y apunta contra los propios datos: cinco algoritmos clasifican sin error la partición de prueba, lo que revela que el conjunto es separable por construcción y que las métricas obtenidas sobre él no estiman la calidad de la estimación de riesgo. Lo presentado es un diseño y un protocolo para someterlo a prueba, no un sistema evaluado.

El trabajo futuro tiene un orden obligado, porque cada paso condiciona la interpretación del siguiente. El primero es medir qué características resultan legibles en fichas reales. Importa menos el porcentaje global que su reparto entre plataformas grandes y vendedores independientes: si la cobertura se concentrara en las primeras, que son las que ya ofrecen garantías al comprador, el sistema fallaría precisamente donde este se encuentra más expuesto. El segundo es construir un conjunto de datos más sólido, cuyas etiquetas provengan de una fuente independiente del vector de entrada y cuyo tamaño y diversidad reflejen la variedad de fichas que el sistema encontrará en operación; sin él, cualquier métrica seguirá midiendo la regla que generó esas etiquetas, como muestra la Sección V-A. Solo una vez resueltos ambos resulta informativa la evaluación con usuarios.

Una línea distinta, que este trabajo no aborda, es la detección del comportamiento fraudulento del vendedor: determinar

si un vendedor defrauda exige evidencia sobre operaciones consumadas y una definición operativa de fraude que el comprador no puede establecer desde la ficha. Es un problema de clasificación con verdad de referencia, no de estimación de riesgo previa a la decisión, y abordarlo requeriría la colaboración de las plataformas o el acceso a denuncias verificadas; constituye por ello una recomendación para investigaciones posteriores antes que una extensión del sistema aquí descrito.

REFERENCIAS

- [1] V. Balakrishnan, U. Ahmmed, and F. Basheer, "Personal, environmental and behavioral predictors associated with online fraud victimization among adults," *PLoS ONE*, vol. 20, no. 1, p. e0317232, Jan. 2025, doi: 10.1371/journal.pone.0317232.
- [2] J. M. Whittaker, M. Edwards, C. Cross, and M. Button, "'I have only checked after the event': Consumer approaches to safe online shopping," *Vict. Offender*, vol. 18, no. 7, pp. 1259–1281, 2023, doi: 10.1080/15564886.2022.2130486.
- [3] K. Zhang, H. Wang, M. Chen, X. Chen, L. Liu, Q. Geng, and Y. Zhou, "Leveraging machine learning to proactively identify phishing campaigns before they strike," *J. Big Data*, vol. 12, Art. no. 124, 2025, doi: 10.1186/s40537-025-01174-x.
- [4] Y. Lei, F. Ødegaard, and H. Pun, "Effect of counterfeits and fake reviews in markets for credence goods," *Omega*, vol. 131, p. 103218, Feb. 2025, doi: 10.1016/j.omega.2024.103218.
- [5] T. Lawanna, "An adaptive CBR-agent AI model for detecting fraudulent user behavior in digital marketplace platforms," *J. Intell. Decis. Making Inf. Sci.*, vol. 3, no. 2, pp. 1210–1236, 2026.
- [6] A. S. Rofiudin, Orvalamarva, and R. R. Saedudin, "Comparative analysis of information security methods in e-commerce environment," *Int. J. Adv. Sci. Eng. Inf. Technol.*, vol. 15, no. 6, pp. 1740–1746, Dec. 2025.
- [7] G. Kostopoulos, A. Stefani, V. Vasiliadis, and S. Kotsiantis, "Deep learning for e-commerce: Recent developments in prediction, personalization and decision intelligence," *Appl. Sci.*, vol. 16, Art. no. 2263, Feb. 2026, doi: 10.3390/app16052263.
- [8] Y. Jiang and P. Du, "Cross-border e-commerce credit risk early warning model based on deep learning," *Int. J. Reasoning-based Intell. Syst.*, vol. 17, no. 10, pp. 1–9, Aug. 2025, doi: 10.1504/IJRS.2025.10072955.
- [9] R. Das *et al.*, "Towards the development of an explainable e-commerce fake review index: An attribute analytics approach," *Eur. J. Oper. Res.*, vol. 317, no. 2, pp. 382–400, Sep. 2024, doi: 10.1016/j.ejor.2024.03.008.
- [10] S. A. Rajaguguk and D. Sofyan, "Detecting sophisticated fake reviews on e-commerce platforms using adversarial transformer networks," *Eng. Technol. Appl. Sci. Res.*, vol. 15, no. 6, pp. 29840–29845, Dec. 2025, doi: 10.48084/etasr.13369.
- [11] J. M. Thilini Jayasinghe and S. Dassanayaka, "Detecting deception: Employing deep neural networks for fraudulent review detection on Amazon," *Neural Comput. Appl.*, vol. 37, no. 26, pp. 21715–21742, Sep. 2025, doi: 10.1007/s00521-025-11485-y.
- [12] A. Mutemi and F. Bacao, "E-commerce fraud detection based on machine learning techniques: Systematic literature review," Sep. 2025, doi: 10.26599/BDMA.2023.9020023.
- [13] A. Janavičiūtė, A. Liutkevičius, G. Dabužinskas, and N. Morkevičius, "Experimental evaluation of possible feature combinations for the detection of fraudulent online shops," *Appl. Sci. (Switzerland)*, vol. 14, no. 2, Jan. 2024, doi: 10.3390/app14020919.
- [14] M. Sánchez-Paniagua, E. Fidalgo, E. Alegre, and F. Jánhez-Martino, "Fraud detection in e-commerce: A comparative analysis of features to enhance machine learning models," *Electron. Commerce Res.*, Apr. 2025, doi: 10.1007/s10660-025-10029-9.
- [15] L. Anand, H.-N. Goh, C.-Y. Ting, and A. Quek, "Identifying fraud sellers in e-commerce platform," Mar. 2025, doi: 10.62527/joiv.9.2.3479.
- [16] S. M. Abd-Alhaleem, H. A. Ali, N. F. Soliman, A. D. Algarni, and H. S. Marie, "Advancing e-commerce authenticity: A novel fusion approach based on deep learning and aspect features for detecting false reviews," *IEEE Access*, vol. 12, pp. 116055–116070, 2024, doi: 10.1109/ACCESS.2024.3435916.
- [17] J. D. Duarte *et al.*, "Machine learning for early detection of phishing URLs in parked domains: An approach applied to a financial institution," *IEEE Access*, vol. 13, pp. 145736–145753, 2025, doi: 10.1109/ACCESS.2025.3599454.
- [18] J. Aurazo and F. Gasmi, "Digital payment systems in emerging economies: Lessons from Kenya, India, Brazil, and Peru," *Inf. Econ. Policy*, vol. 69, p. 101113, Dec. 2024, doi: 10.1016/j.infoecopol.2024.101113.
- [19] T. N. Tran, L. D. Nghi, and D. T. K. Chinh, "Perceived risk and trust as moderators between online shopping intention and purchase decisions," *Emerg. Sci. J.*, vol. 10, no. 2, pp. 1101–1116, Apr. 2026, doi: 10.28991/ESJ-2026-010-02-026.
- [20] C. Bianchi and M. A. Saleh, "Investigating the drivers of e-commerce continuance intentions among older consumers in Latin America," *J. Internet Commerce*, vol. 23, no. 4, pp. 384–413, 2024, doi: 10.1080/15332861.2024.2424141.
- [21] P. Landeta-López, J. M. García, C. Guevara-Vega, and A. Ruiz-Cortés, "LLMs applied to web scraping and web crawling: A systematic review," *Computing*, vol. 108, Art. no. 78, May 2026, doi: 10.1007/s00607-026-01666-5.
- [22] J. Brooke, "SUS—A quick and dirty usability scale," in *Usability Evaluation in Industry*, P. W. Jordan, B. Thomas, B. A. Weerdmeester, and I. L. McClelland, Eds. London, U.K.: Taylor & Francis, 1996, pp. 189–194.